

大模型 (LLMs) 基础面

来自: AiGC面试宝典



宁静致远

2023年09月28日 21:50




三

大模型 (LLMs) 基础面

- 大模型 (LLMs) 基础面
 - 1 目前 主流的开源模型体系 有哪些?
 - 2 prefix Decoder 和 causal Decoder 和 Encoder-Decoder 区别是什么?
 - 3 大模型 LLM 的 训练目标 是什么?
 - 4 涌现能力是啥原因?
 - 5 为何现在的大模型大部分是 Decoder only 结构?
 - 6 简单 介绍一下 大模型【LLMs】?
 - 7 大模型【LLMs】后面跟的 175B、60B、540B 等 指什么?
 - 8 大模型【LLMs】具有什么优点?
 - 9 大模型【LLMs】具有什么缺点?

目前 主流的开源模型体系 分三种：


- 第一种：prefix Decoder 系
 - 介绍：输入双向注意力，输出单向注意力
 - 代表模型：ChatGLM、ChatGLM2、U-PaLM
- 第二种：causal Decoder 系
 - 介绍：从左到右的单向注意力
 - 代表模型：LLaMA-7B、LLaMa 衍生物
- 第三种：Encoder-Decoder
 - 介绍：输入双向注意力，输出单向注意力
 - 代表模型：T5、Flan-T5、BART



2 prefix Decoder 和 causal Decoder 和 Encoder-Decoder 区别是什么？

prefix Decoder 和 causal Decoder 和 Encoder-Decoder 区别在于 attention mask 不同：

- Encoder-Decoder:
 - 在输入上采用双向注意力，对问题的编码理解更充分
 - 适用任务：在偏理解的 NLP 任务上效果好
 - 缺点：在长文本生成任务上效果差，训练效率低；
- causal Decoder:
 - 自回归语言模型，预训练和下游应用是完全一致的，严格遵守只有后面的 token 才能看到前面的 token 的规则；
 - 适用任务：文本生成任务效果好
 - 优点：训练效率高，zero-shot 能力更强，具有涌现能力
- prefix Decoder:
 - 特点：prefix 部分的 token 互相能看到，causal Decoder 和 Encoder-Decoder 折中；
 - 缺点：训练效率低



3 大模型 LLM 的训练目标 是什么？

1. 语言模型

根据 已有词 预测下一个词，训练目标为最大似然函数：

$$\mathcal{L}_{LM}(x) = \sum_{i=1}^n \log P(x_i | x_{<i})$$

训练效率：Prefix Decoder < Causal Decoder

Causal Decoder 结构会在 所有 token 上计算损失，而 Prefix Decoder 只会 在 输出上 计算损失。

1. 去噪自编码器

随机替换掉一些文本段，训练语言模型去恢复被打乱的文本段。目标函数为：

$$\mathcal{L}_{DAE}(x) = \log P(\tilde{x} | x_{/\tilde{x}})$$

去噪自编码器的实现难度更高。采用去噪自编码器作为训练目标的任务有 GLM-130B、T5。

4 涌现能力是啥原因？

根据前人分析和论文总结，大致是 2 个猜想：

- 任务的评价指标不够平滑；
- 复杂任务 vs 子任务，这个其实好理解，比如我们假设某个任务 T 有 5 个子任务 Sub-T 构成，每个 sub-T 随着模型增长，指标从 40% 提升到 60%，但是最终任务的指标只从 1.1% 提升到了 7%，也就是说宏观上看到了涌现现象，但是子任务效果其实是平滑增长的。

5 为何现在的大模型大部分是 Decoder only 结构？

因为 **decoder-only** 结构模型在没有任何微调数据的情况下，**zero-shot** 的表现能力最好。而 **encoder-decoder** 则需要在一定量的标注数据上做 **multitask-finetuning** 才能够激发最佳性能。

目前的 **Large LM** 的训练范式还是在大规模语料 **shang** 做自监督学习，很显然 **zero-shot** 性能更好的 **decoder-only** 架构才能更好的利用这些无标注的数据。

大模型使用 **decoder-only** 架构除了训练效率和工程实现上的优势外，在理论上因为 **Encoder** 的双向注意力会存在低秩的问题，这可能会削弱模型的表达能力。就生成任务而言，引入双向注意力并无实质的好处。而 **Encoder-decoder** 模型架构之所以能够在某些场景下表现更好，大概是因为它多了一倍参数。所以在同等参数量、同等推理成本下，**Decoder-only** 架构就是最优的选择了。

6 简单介绍一下 大模型【LLMs】？

大模型：一般指 **1 亿以上参数的模型**，但是这个标准一直在升级，目前万亿参数以上的模型也有了。大语言模型（**Large Language Model**，**LLM**）是针对语言的大模型。

7 大模型【LLMs】后面跟的 175B、60B、540B 等 指什么？

175B、60B、540B 等：这些一般指参数的个数，**B** 是 **Billion/十亿** 的意思，**175B** 是 **1750 亿** 参数，这是 **ChatGPT** 大约的参数规模。

8 大模型【LLMs】具有什么优点？

1. 可以利用大量的无标注数据来训练一个通用的模型，然后再用少量的有标注数据来微调模型，以适应特定的任务。这种预训练和微调的方法可以减少数据标注的成本和时间，提高模型的泛化能力；
2. 可以利用生成式人工智能技术来产生新颖和有价值的内容，例如图像、文本、音乐等。这种生成能力可以帮助用户在创意、娱乐、教育等领域获得更好的体验和效果；
3. 可以利用涌现能力（**Emergent Capabilities**）来完成一些之前无法完成或者很难完成的任务，例如数学应用题、常识推理、符号操作等。这种涌现能力可以反映模型的智能水平和推理能力。

9 大模型【LLMs】具有什么缺点？

1. 需要消耗大量的计算资源和存储资源来训练和运行，这会增加经济 and 环境的负担。据估计，训练一个 GPT-3 模型需要消耗约 30 万美元，并产生约 284 吨二氧化碳排放；
2. 需要面对数据质量和安全性的问题，例如数据偏见、数据泄露、数据滥用等。这些问题可能会导致模型产生不准确或不道德的输出，并影响用户或社会的利益；
3. 需要考虑可解释性、可靠性、可持续性等方面的挑战，例如如何理解和控制模型的行为、如何保证模型的正确性和稳定性、如何平衡模型的效益和风险等。这些挑战需要多方面的研究和合作，以确保大模型能够健康地发展。