



大模型 (LLMs) 评测面

来自: AiGC面试宝典

宁静致远

2023年09月29日 10:23

- 大模型 (LLMs) 评测面
  - 1 大模型怎么评测?
  - 2 大模型的honest原则是如何实现的? 模型如何判断回答的知识是训练过的已知的知识, 怎么训练这种能力?
  - 3 如何衡量大模型水平?
  - 4 大模型评估方法 有哪些?
  - 5 大模型评估工具 有哪些?
  - 6介绍一下 困惑度?
  - 7 大模型训练的性能指标:吞吐率 Throughput 是指什么?
  - 8 如何评价大语言模型的训练数据的质量?

1 大模型怎么评测?

当前 superGLUE, GLUE, 包括中文的 CLUE 的 benchmark 都在不太合适评估大模型。可能评估推理能力、多轮对话能力是核心。

2 大模型的 honest 原则是如何实现的? 模型如何判断回答的知识是训练过的已知的知识, 怎么训练这种能力?

大模型需要遵循的 helpful, honest, harmless 的原则。

可以有意构造如下的训练样本, 以提升模型准守 honest 原则, 可以算 trick 了:

微调时构造知识问答类训练集, 给出不知道的不回答, 加强 honest 原则;

阅读理解题, 读过的要回答, 没读过的不回答, 不要胡说八道。

### 3 如何衡量大模型水平？

要评估一个大型语言模型的水平，可以从以下几个维度提出具有代表性的问题。

- 理解能力：提出一些需要深入理解文本的问题，看模型是否能准确回答。
- 语言生成能力：让模型生成一段有关特定主题的文章或故事，评估其生成的文本在结构、逻辑和语法等方面的质量。
- 知识面广度：请模型回答关于不同主题的问题，以测试其对不同领域的知识掌握程度。这可以是关于科学、历史、文学、体育或其他领域的问题。一个优秀的大语言模型应该可以回答各种领域的问题，并且准确性和深度都很高。
- 适应性：让模型处理各种不同类型的任务，例如：写作、翻译、编程等，看它是否能灵活应对。
- 长文本理解：提出一些需要处理长文本的问题，例如：提供一篇文章，让模型总结出文章的要点，或者请模型创作一个故事或一篇文章，让其有一个完整的情节，并且不要出现明显的逻辑矛盾或故事结构上的错误。一个好的大语言模型应该能够以一个连贯的方式讲述一个故事，让读者沉浸其中。
- 长文本生成：请模型创作一个故事或一篇文章，让其有一个完整的情节，并且不要出现明显的逻辑矛盾或故事结构上的错误。一个好的大语言模型应该能够以一个连贯的方式讲述一个故事，让读者沉浸其中。
- 多样性：提出一个问题，让模型给出多个不同的答案或解决方案，测试模型的创造力和多样性。
- 情感分析和推断：提供一段对话或文本，让模型分析其中的情感和态度，或者推断角色间的关系。
- 情感表达：请模型生成带有情感色彩的文本，如描述某个场景或事件的情感、描述一个人物的情感状态等。一个优秀的大语言模型应该能够准确地捕捉情感，将其表达出来。
- 逻辑推理能力：请模型回答需要进行推理或逻辑分析的问题，如概率或逻辑推理等。这可以帮助判断模型对推理和逻辑思考的能力，以及其在处理逻辑问题方面的准确性。例如：“所有的动物都会呼吸。狗是一种动物。那么狗会呼吸吗？”

- 问题解决能力：提出实际问题，例如：数学题、编程问题等，看模型是否能给出正确的解答。
- 道德和伦理：测试模型在处理有关道德和伦理问题时的表现，例如：“在什么情况下撒谎是可以接受的？”
- 对话和聊天：请模型进行对话，以测试其对自然语言处理的掌握程度和能力。一个优秀的大语言模型应该能够准确地回答问题，并且能够理解人类的语言表达方式。

#### 4 大模型评估方法 有哪些？

- 人工评估：LIMA、Phoenix
- 使用 GPT-4 的反馈进行自动评估：Vicuna、Phoenix、Chimera、BELLE 指标评估（BLEU-4、ROUGE 分数）：ChatGLM-6B；对于像 ROUGE-L 分数的指标评估，有些地方称其为非自然指令评估（Unnatural Instruction Evaluation）。
- Chatbot Arena：目前用来衡量一个模型好不好东西基本都是基于一些学术的 **benchmark**，比如在一个某个 NLP 任务上构建一个测试数据集，然后看测试数据集上准确率多少。然而，这些学术 **benchmark**（如 HELM）在大模型和聊天机器人上就不好用了。其原因在于：
  - 由于评判聊天机器人聊得好不好这件事是非常主观的，因此，现有的方法很难对其进行衡量。
  - 这些大模型在训练的时候就几乎把整个互联网的数据都扫了一个遍，因此，很难保证测试用的数据集没有被看到过。

甚至更进一步，用测试集直接对模型进行「特训」，如此一来表现必然更好。

- 理论上我们可以和聊天机器人聊任何事情，但很多话题或者任务在现存的 **benchmark** 里面根本就不存在。

因此，Chatbot Arena 的做法是放弃 **benchmark**，通过对抗，实时聊天，两两比对人工进行打分，采用 **elo** 分数进行评测。

## 5 大模型评估工具 有哪些?

- **OpenAI evals**: OpenAI 的自动化评估脚本, 核心思路就是通过写 **prompt** 模版来自动化评估。
- **PandaLM**: 其是直接训练了一个自动化打分模型, 0,1,2 三分制用模型对两个候选模型进行打分。

## 6 介绍一下 困惑度?

困惑度:一般来说是用来评价语言型好坏的指标。语言模型是衡量句子好坏的模型, 本质上是计算句子的概率。

## 7 大模型训练的性能指标:吞吐率 **Throughput** 是指什么?

吞吐率(Throughput)是指系统在单位时间内能够处理的任务数或操作数。吞吐率通常以每秒钟处理的任务数(例如, 每秒处理的训练步骤或样本数)来衡量。对于大模型的训练, 吞吐率是一个关键的性能指标, 因为它直接影响大模型训练的速度和效率。

---

通俗来说, 吞吐率表示了模型在一秒内能够处理多少个训练步骤或样本。想象一下你在做一项任务, 比如洗碗, 如果你每分钟能够洗 10 个碗, 那么你的洗 a 碗吞吐率就是 10 个碗 /分钟。

对于大模型训练, 提高吞吐率意味着计算机系统更有效率地完成任务, 就好比工厂工人更快速地组装产品。通过采用各种技术策略, 如并行计算、批处理和分布式训练, 可以帮助提高吞吐率, 从而加速大型深度学习模型的训练过程。

总的来说, 吞吐率高意味着模型训练速度快, 这对于大模型的训练任务来说非常重要, 因为可以更迅速地得到训练好的模型, 它是衡量训练效果和经济性的重要标志。

## 8 如何评价大语言模型的训练数据的质量?

大语言模型的训练数据质量是非常重要的, 训练数据的质量直接影响模型的性能和泛化能力。结合实际经验, 我整理了以下这些评价大语言模型训练数据质量的关键要点:



- 内容多样性:训练大语言模型的时候,我们要确保用到的数据集来自不同的地方、文化和主题,这样模型才能更全面地理解和学到各种内容。
- 来源代表性:数据集里的例子应该反映出模型可能遇到的各种情境和用途,比如包含不同地区、文化和社会群体的内容,这样模型在不同情境下才能表现好。
- 语义质量:数据尽量做到准确无误,符合语法和语义规则。低质量的数据可能导致模型学到错误的信息。

- 
- 实时性:数据要比较新,因为语言和信息会不断变化。老旧的数据可能不反映出当前的语言和文化使用。
  - 隐私和道德:确保数据的采集和使用是合法和道德的,尊重用户的隐私。不要用可能引起纷争或违反伦理准则的数据。
  - 标注质量:如果数据有标注,要确保标注是正确的,符合实际情境。错误的标注可能导致模型学到错误的规律。
  - 去偏与去重:要处理数据的偏向,避免模型过于依赖某些特定例子。同时,去掉重复的内容,避免模型学到重复的信息。
  - 中立性:确保所选择的数据内包含的观点尽可能中立,以避免引起不必要的纷争。

总的来说,好的训练数据应该是多样的、代表性强、质量高、平衡分布的,并且符合隐私和道德规范,这样可以让训练出的大语言模型在各种场景下都能够表现的较为稳定。