

大模型 (LLMs) 强化学习—— PPO 面

来自: AiGC面试宝典

 Just do it!

2024年05月05日 11:18



大模型 (LLMs) 强化学习—— PPO 面

- 一、大语言模型RLHF中的PPO主要分哪些步骤?
- 二、举例描述一下 大语言模型的RLHF?
- 三、大语言模型RLHF 采样篇
 - 3.1 什么是 PPO 中 采样过程?
 - 3.2 介绍一下 PPO 中 采样策略?
 - 3.3 PPO 中 采样策略中, 如何评估“收益”?
- 四、在PPO过程中, reward model的效果上会有什么问题?
- 五、如何解决reward model的OOD的问题?
- 六、RLHF中PPO有什么问题, 为什么大家都设计很多方法去替代它?

一、大语言模型 RLHF 中的 PPO 主要分哪些步骤?

大语言模型 RLHF 中的 PPO 分为:

1. 采样
2. 反馈
3. 学习

对应的实现逻辑如下:

```
policy_model = load_model()

for k in range(20000):
    # 采样 (生成答案)
    prompts = sample_prompt()
    data = respond(policy_model, prompts)

    # 反馈 (计算奖励)
    rewards = reward_func(reward_model, data)

    # 学习 (更新参数)
    for epoch in range(4):
        policy_model = train(policy_model, prompts, data, rewards)
```

二、举例描述一下 大语言模型的 RLHF ?

大语言模型的 RLHF，实际上是模型先试错再学习的过程。

大语言模型的 RLHF 好比是：老师与学生的角色

- 我们扮演着老师的角色，给出有趣的问题。模型则会像小学生一样，不断尝试给出答案。
- 模型会根据我们给出的问题，写出它觉得正确的答案，但是这些答案不一定是真的答案，需要我们结合正确答案进行打分。如果它表现得好，就会给予它高声赞扬；如果它表现不佳，我们则会给予它耐心的指导和反馈，帮助它不断改进，直到达到令人满意的水平。

三、大语言模型 RLHF 采样篇

3.1 什么是 PPO 中 采样过程？

PPO 中 采样过程：学生回答问题的过程，是模型根据提示（prompt）输出回答（response）的过程，或者说是模型自行生产训练数据的过程。

prompt	response
请告诉我三种常见的动物。	猫，狗，鹦鹉。
如何评价电影《爱乐之城》？	音乐的经典令人赞叹不已，结局却让人感到五味杂陈。
詹姆斯和库里谁更伟大？	他们都很伟大，我无法比较。

3.2 介绍一下 PPO 中 采样策略？

PPO 中 采样工作 通过一种 策略 (policy)：policy 由两个模型组成，一个叫做演员模型 (Actor)，另一个叫做评论家模型 (Critic)。它们就像是学生大脑中的两种意识，一个负责决策，一个负责总结得失。

演员：我们想要训练出来的大模型。在用 PPO 训练它之前，它就是 RLHF 的第一步训练出来的 SFT (Supervised Fine-Tuning) model。输入一段上下文，它将输出下一个 token 的概率分布。

评论家：强化学习的辅助模型，输入一段上下文，它将输出下一个 token 的“收益”。

3.3 PPO 中 采样策略中，如何评估“收益”？

从下一个 token 开始，模型能够获得的总奖励(浮点数标量)。这里说的奖励包括 Reward Model 给出的奖励。

四、在 PPO 过程中，reward model 的效果上会有什么问题？

在模型 PPO 过程中，reward model 的准确率逐渐下降，这就是俗称的 reward model 的 OOD 问题，因为 reward model 的训练样本一般来自 sft 模型的 responses，那么在 PPO 过程中，policy model 刚开始和 sft 生成的 response 很相似，所以 reward model 准确率较高，但是在逐渐偏离 sft 的时候，reward model 的准确率会持续下降，这基本就是现阶段 reward model 的主要问题。我个人认为 AGI 过程中，一定需要一个 generalize 很强的 reward model，就是所谓的 global reward model or world model。

五、如何解决 reward model 的 OOD 的问题？

现阶段解决 reward model 的 OOD 普遍解决方法，就是 Llama2 [1]的做法，也就是在训练过一段时间 RLHF 以后，重新对 policy 采样 pair 对，人标数据然后继续训练 reward model。但这种方式就是太费人力，感觉并不是持久之道。

除此之外也有一些 paper 试图解决这个问题：

- 比如 [Secrets of RLHF in Large Language Models Part II: Reward Modeling \[2\]](#) 中，通过 meta learning 的方式解决这个问题，整体思想就是由于 policy model 在 reward model 训练情况下会向 reward 高的方向更新，所以 reward model 应该对 reward 高的 response pair 更有区分度，所以设置 gradient 更新逐渐倾向于对 reward 高分 training response pair 倾斜。这种方法比较 make sense，但实际上，由于缺少对模型 on policy 的采样，效果不太好。
- [West-of-N: Synthetic Preference Generation for Improved Reward Modeling \[3\]](#) 这篇文章跟 Llama2 的方式相似，区别就是不再用人进行标记，而是通过 reward model 本身对新的模型 on policy pair 进行打分，取一个 query 的 response set 中最高的分数和最低的分数数据组 pair，加入到 reward model 的训练中。个人感觉这种方式的采样，虽然通过 on policy 采样加强 rm 的泛化能力，但实际上上受限受原先 rm model 的能力影响。

个人觉得如何做出泛化能力比较强的 rm 会是一个比较难，也是比较限制模型发展的问

题。

- [1]Touvron H, Martin L, Stone K, et al. Llama 2: Open foundation and fine-tuned chat models[J]. arXiv preprint arXiv:2307.09288, 2023.
- [2]Wang B, Zheng R, Chen L, et al. Secrets of rlhf in large language models part ii: Reward modeling[J]. arXiv preprint arXiv:2401.06080, 2024.
- [3]Pace A, Mallinson J, Malmi E, et al. West-of-N: Synthetic Preference Generation for Improved Reward Modeling[J]. arXiv preprint arXiv:2401.12086, 2024.

六、RLHF 中 PPO 有什么问题，为什么大家都设计很多方法去替代它？

- 1. Notable Complexity: 由于 PPO 中需要 4 个模型同时加载在 GPU 中， policy model， ref policy model， value model， reward model。所以会占用很多 GPU 机器。
- 2. Online learning problem, 除此之外，由于模型是 online 采样，在 policy 过 batch samples 的时候， reward model 会空置，在 reward model 给 pair 打分的时候， policy model 也会空置，那么 GPU 利用率会不高。
- 3. PPO 的调超参数会比较困难，需要一些炼丹高手和经验去做。

参考

- Asynchronous Methods for Deep Reinforcement Learning (2016): <https://arxiv.org/abs/1602.01783>
- Proximal Policy Optimization Algorithms (2017): <https://arxiv.org/abs/1707.06347>
- Fine-Tuning Language Models from Human Preferences (2020): <https://arxiv.org/abs/1909.08593>
- Learning to Summarize from Human Feedback (2022) :<https://arxiv.org/abs/2009.01325>
- LLM 预训练之 RLHF (一) : RLHF 及其变种 <https://zhuanlan.zhihu.com/p/657045745>
- 拆解大语言模型 RLHF 中的 PPO <https://zhuanlan.zhihu.com/p/645225982>
- 大模型的面试题系列-8 <https://zhuanlan.zhihu.com/p/686257197>
- 大模型的面试题系列-12 <https://zhuanlan.zhihu.com/p/686773718>
- 大模型的面试题系列-13 <https://zhuanlan.zhihu.com/p/686978224>