



大模型 (LLMs) 分布式训练面

来自: AiGC面试宝典

宁静致远

2023年09月29日 10:37

1. 理论篇

1.1 训练 大语言模型 存在问题?


- **显存效率:模型参数量太大, 显存不够用**

即使目前显存最大的GPU也放不下这些大模型的模型参数。例如:175B参数量的GPT3模型参数需要占用700GB (175B*4bytes) 的显存。参数梯度是700GB,Adam优化器状态需要1400GB, 共计需要2.8TB的显存。

- **计算效率:训练数据量多, 模型参数量大, 计算量大, 单机训练时间久**


即使我们能将大模型放在一张GPU上, 训练大模型需要的海量计算操作需要耗费很长时间。例如:用英伟达A100显卡训练175B参数量的GPT3模型大约需要288年。

1.2 什么是 点对点通信?



- 点对点通信 思路:一个进程发送数据, 一个进程接收数据
- 优点: 速度快, 成本低


1.3 什么是 集体通信?



- 集体通信思路:多个进程发送数据, 多个进程接收数据。
- 缺点: 速度慢, 成本高

1.4 什么是 数据并行?

- 介绍: 将整个数据集切分为多份, 每张GPU分配到不同的数据进行训练, 每个进程都有一个完整的模型副本。




- 关键: 保证多个GPU上的模型副本是相同的
 - 1. 确保所有worker都从相同的初始化模型参数开始训练。在训练开始前, 通常会将0号卡的1模型参数通信同步到其他卡。
 - 2. 每次训练迭代中, 在后向传递之后, 优化器更新参数之前, 插入reduce通信操作来规约梯度, 确保所有worker上的梯度都是相同的。
- 通过以上两点, 在优化器更新后, 也可以保证所有worker上的模型参数是相同的。

相同的初始化模型参数 + 相同的梯度 --> 相同的模型参数。


1.5 数据并行 如何 提升效率？

- 1. 梯度分桶:动机是集体通信在大张量上比在小张量上效率更高。
- 2. 计算与通信重叠:有了梯度分桶之后，在等待同一个桶内的梯度计算完后，就可以进行通信操作
- 3. 跳过梯度同步: 梯度累加，减少梯度通信的频次。




1.6 什么是 流水线并行？

- 1. 层间划分，将不同的层划分到不同的GPU上
- 2. 前3层在0号卡上，后3层在1号卡上




1.7 什么是 张量并行 (intra-layer)?

- 层内划分，切分一个独立的层划分到不同的GPU上
- 0号卡和1号卡分别计算某个层的不同部分



对于一个简单的矩阵乘法GEMMs $Y = XA$
按照对权重矩阵A的分块方式，张量并行分为行并行和列并行。




1.8 数据并行 vs 张量并行 vs 流水线并行？

- 数据并行:计算效率高、实现简单。
 - 显存效率:每张卡上都保存了完整的模型、梯度、优化器状态，因此显存效率不高
 - 计算效率:当增加并行度时，单卡的计算量是保持恒定的，可以实现近乎完美的线性扩展。但规约梯度的通信开销，与模型大小成正相关。
- 张量并行:因模型结构而异，实现难度大。
 - 显存效率:随着并行度增加，成比例地减少显存占用。是减少单层神经网络中间激活的唯一方法
 - 计算效率:频繁的通信，限制了两个通信阶段之间的计算量，影响了计算效率，计算效率很低。
- 流水线并行:通信成本最低
 - 显存效率:减少的显存与流水线并行度成正比。但流水线并行不会减少每层中间激活的显存占用
 - 计算效率:成本更低的点对点(P2P)通信。通信量与流水线各个阶段边界的激活值大小成正比。

显存效率:模型并行>流水线并行>数据并行

通信效率:流水线并行>数据并行>模型并行

1.9 什么是 3D并行？



3D并行。4路张量并行，4路流水线并行，2路数据并行。共32个workers。

1.10 想要训练1个LLM，如果只想用1张显卡，那么对显卡的要求是什么？

显卡显存足够大，nB模型微调一般最好准备20nGB以上的显存。

1.11 如果有N张显存足够大的显卡，怎么加速训练？

数据并行（DP），充分利用多张显卡的算力。

1.12 如果显卡的显存不够装下一个完整的模型呢？

最直观想法，需要**分层加载**，把不同的层加载到不同的GPU上（accelerate的device_map）

也就是常见的PP，流水线并行。

1.13 PP推理时，是一个串行的过程，1个GPU计算，其他空闲，有没有其他方式？

- **横向切分：流水线并行（PP）**，也就是分层加载到不同的显卡上。
- **纵向切分：张量并行（TP）**，在 [DeepSpeed](#) 世界里叫模型并行（MP）

1.14 3种并行方式可以叠加吗？

是可以的，**DP+TP+PP**，这就是3D并行。**如果真有1个超大模型需要预训练，3D并行那是必不可少的。**毕竟显卡进化的比较慢，最大显存的也就是A100 80g。

单卡80g，可以完整加载小于40B的模型，但是训练时+梯度+优化器状态，5B模型就是上限了，更别说activation的参数也要占显存，batch size还得大。而现在100亿以下（10B以下）的LLM只能叫small LLM。

1.15 Colossal-AI 有1D/2D/2.5D/3D，是什么情况？

[Colossal-AI](#) 的nD是针对张量并行，指的是TP的切分，对于矩阵各种切，和3D并行不是一回事。


1.16 除了3D并行有没有其他方式大规模训练？

可以使用更优化的数据并行算法FSDP（类似ZeRO3）或者直接使用 [DeepSpeed ZeRO](#)。

1.17 有了ZeRO系列，为什么还需要3D并行？

根据ZeRO论文，尽管张量并行的显存更省一点，张量并行的通信量实在太高，只能限于节点内（有NVLINK）。如果节点间张量并行，显卡的利用率会低到5%

但是，根据Megatron-LM2的论文，当显卡数量增加到千量级，ZeRO3是明显不如3D并行的。



1.18 平民适不适合玩3D并行？

不适合。

3D并行的基础是，节点内显卡间NVLINK超高速连接才能上TP。有没有NVLINK都是个问题。

而且，节点间特殊的网络通常有400Gb/s？远超普通IDC内的万兆网络10Gb/s。

1.19 平民适不适合直接上多机多卡的ZeRO3（万兆网）？

不适合。

想象一下，当65B模型用Zero3，每一个step的每一张卡上需要的通信量是195GB（3倍参数量），也就是1560Gb。万兆网下每步也要156s的通信时间，这画面太美。

1.20 分布式并行及显存优化技术并行技术有哪些，都有什么特点？

分布式并行及显存优化技术并行技术：

- 数据并行（如：PyTorch DDP）
- 模型/张量并行（如：Megatron-LM（1D）、Colossal-AI（2D、2.5D、3D））
- 流水线并行（如：GPipe、PipeDream、PipeDream-2BW、PipeDream Flush（1F1B））
- 多维混合并行（如：3D并行（数据并行、模型并行、流水线并行））
- 自动并行（如：Alpa（自动算子内/算子间并行））
- 优化器相关的并行（如：ZeRO（零冗余优化器，在执行的逻辑上是数据并行，但可以达到模型并行的显存优化效果）、PyTorch FSDP）

1.21 显存优化技术有哪些，都有什么特点？

显存优化技术：

- 重计算(Recomputation)：Activation checkpointing(Gradient checkpointing)，本质上是一种用时间换空间的策略。
- 卸载 (Offload) 技术：一种用通信换显存的方法，简单来说就是让模型参数、激活值等在CPU内存和GPU显存之间左右横跳。如：ZeRO-Offload、ZeRO-Infinity等。
- 混合精度 (BF16/FP16)：降低训练显存的消耗，还能将训练速度提升2-4倍。
 - BF16 计算时可避免计算溢出，出现Inf case。
 - FP16 在输入数据超过65506 时，计算结果溢出，出现Inf case。

1.22 常见的分布式训练框架哪一些，都有什么特点？

- 第一类：深度学习框架自带的分布式训练功能。如：TensorFlow、PyTorch、MindSpore、Oneflow、PaddlePaddle等。
- 第二类：基于现有的深度学习框架（如：PyTorch、Flax）进行扩展和优化，从而进行分布式训练。如：Megatron-LM（张量并行）、DeepSpeed（Zero-DP）、Colossal-AI（高维模型并行，如2D、2.5D、3D）、Alpa（自动并行）等

2. 实践篇

2.1 假如有超多的8卡A100节点（DGX A100），如何应用3D并行策略？

- 首先，**张量并行**。3种并行方式里，张量并行（TP）对于GPU之间的通信要求最高，而节点内有NVLINK通信速度可以达到600GB/s。
- 其次，**流水线并行**，每个节点负责一部分层，每35个节点组成一路完整的流水线，也就是一个完整的模型副本，这里一个模型副本需280卡。
- 最后，**数据并行**，官方也做了8路，10路，12路的并行实验，分别使用280个节点，350个节点和420个节点。

参考 [Megatron-Turing NLG 530B](#)

集群规模越大，单个GPU利用率越低。

2.2 如果想构这样一个大规模并行训练系统，训练框架怎么选？

可以参考Megatron-Turing NLG 530B，NVIDIA Megatron-LM + Microsoft DeepSpeed

[BLOOM](#) 则是PP+DP用DeepSpeed，TP用Megatron-LM

当然还有一些其他的训练框架，在超大规模下或许也能work。

2.3 训练框架怎么选？

下面这个图是bloom的一个实验，DP/TP/PP都能降显存，核心是要降到单卡峰值80g以下。

真大模型就是要TP=8，充分利用NVLINK，然后优先PP，最后DP。

GPUs	Size	DP	TP	PP	MBS	Mem	TFLOPs	Notes
8	20B	1	8	1	1	68GB	107.48	02-17
80	200B	1	8	10	1	75GB	97.82	02-17
160	200B	2	8	10	1	53GB	96.19	02-17

然而假大模型（7B）比如LLaMA-7B，可以不用3D并行，直接用DeepSpeed ZeRO更方便，参考open-llama项目。

3. 并行化策略选择篇

3.1 如何选择一款分布式训练框架？

- 训练成本：不同的训练工具，训练同样的大模型，成本是不一样的。对于大模型，训练一次动辄上百万/千万美元的费用。合适的成本始终是正确的选择。
- 训练类型：是否支持数据并行、张量并行、流水线并行、多维混合并行、自动并行等
- 效率：将普通模型训练代码变为分布式训练所需编写代码的行数，我们希望越少越好。
- 灵活性：你选择的框架是否可以跨不同平台使用？

3.2 如何选择一款分布式训练框架？

- TPU + XLA + TensorFlow/JAX：由Google主导，由于TPU和自家云平台GCP深度绑定。
- GPU + PyTorch + Megatron-LM + DeepSpeed：由NVIDIA、Meta、MicroSoft大厂加持，社区氛围活跃，也更受到大家欢迎。

3.3 单GPU

- 显存够用：直接用
- 显存不够：上offload，用cpu

3.4 单节点多卡

- 显存够用（模型能装进单卡）：DDP或ZeRO
- 显存不够：TP或者ZeRO或者PP

重点：没有NVLINK或者NVSwitch，也就是穷人模式，要用P

3.5 多节点多卡

如果节点间通信速度快（穷人的万兆网肯定不算）

ZeRO或者3D并行，其中3D并行通信量少但是对模型改动大。

如果节点间通信慢，但显存又少。

DP+PP+TP+ZeRO-1

4. 问题篇

4.1 推理速度验证

ChatGML在V100单卡的推理耗时大约高出A800单卡推理的40%。

ChatGML推理耗时和问题输出答案的字数关系比较大，答案字数500字以内，A800上大概是每100字，耗时1秒，V100上大概是每100字，耗时1.4秒。

1. ChatGML在A800单卡推理耗时统计

问题	运 行 次 数	平 均 答 案 长度	平均耗时
给我介绍一下苹果公司,50个字	5	146.6	1.9458990097045898
给我介绍一下微软公司,50个字	5	104.6	1.2978283882141113
给我介绍一下苹果公司,100个字	5	165.4	2.0990972995758055
给我介绍一下微软公司,100个字	5	154.4	1.9092102527618409
给我介绍一下苹果公司,200个字	5	168.4	2.1302066326141356
给我介绍一下微软公司,200个字	5	208.8	2.6089860916137697
给我介绍一下苹果公司,300个字	5	443.4	5.4034130573272705
给我介绍一下微软公司,300个字	5	484.2	5.980589342
给我介绍一下苹果公司,500个字	5	525.4	6.246328496932984
给我介绍一下微软公司,500个字	5	591.6	6.961390399932862

1. ChatGML在V100单卡推理耗时统计

问题	运 行 次 数	平 均 答 案 长度	平均耗时
给我介绍一下苹果公司,50个字	5	138.4	2.761659336090088
给我介绍一下微软公司,50个字	5	78.8	1.5739593029022216
给我介绍一下苹果公司,100个字	5	144.6	2.872290754318237
给我介绍一下微软公司,100个字	5	180.8	3.492029619216919
给我介绍一下苹果公司,200个字	5	168.8	3.4686755657196047
给我介绍一下微软公司,200个字	5	268.6	5.267689609527588
给我介绍一下苹果公司,300个字	5	460.2	9.266673517227172
给我介绍一下微软公司,300个字	5	472.2	9.080669832229614
给我介绍一下苹果公司,500个字	5	558	11.044233322143555
给我介绍一下微软公司,500个字	5	585.4	11.413637781143189

- 结论：
- 训练效率方面: 多机多卡训练，增加训练机器可以线性缩短训练时间。

• 推理性能方面:

• ChatGML在V100单卡的推理耗时大约高出A800单卡推理的40%。

• ChatGML推理耗时和问题输出答案的字数关系比较大，答案字数500字以内，A800上大概是每100字，耗时1秒，V100上大概是每100字，耗时1.4秒。

4.2 并行化训练加速

可采用deepspeed进行训练加速，目前行业开源的大模型很多都是采用的基于deepspeed框架加速来进行模型训练的。如何进行deepspeed训练，可以参考基于[deepspeed构建大模型分布式训练平台](#)。

deepspeed在深度学习模型软件体系架构中所处的位置：

DL model—>train opitimization(deepspeed)—>train framework —> train instruction (cloud)—>GPU device

当然需要对比验证deepspeed 的不同参数，选择合适的参数。分别对比stage 2,3进行验证，在GPU显存够的情况下，最终使用stage 2。

4.3 deepspeed 训练过程，报找不主机

解决方法：deepspeed的关联的多机的配置文件，Hostfile 配置中使用ip，不使用hostname

4.4 为什么 多机训练效率不如单机？

多机训练可以跑起来，但是在多机上模型训练的速度比单机上还慢。

通过查看服务器相关监控，发现是网络带宽打满，上不去了，其他系统监控基本正常。原理初始的多机之间的网络带宽是64Gps，后面把多机之间的网络带宽调整为800Gps，问题解决。

实验验证，多机训练的效率，和使用的机器数成线性关系，每台机器的配置一样，如一台GPU机器跑一个epoch需要2小时，4台GPU机器跑一个epoch需要半小时。除了训练速度符合需求，多机训练模型的loss下降趋势和单机模型训练的趋势基本一致，也符合预期。

4.5 多机训练不通，DeepSpeed配置问题

多机间NCCL 不能打通

- 解决方法：

新建 .deepspeed_env 文件，写入如下内容

```
NCCL_IB_DISABLE=1
NCCL_DEBUG=INFO
NCCL_SOCKET_IFNAME=eth0
NCCL_P2P_DISABLE=1
```

总结

如果没有NVLINK和节点间还是万兆网的穷人，TP别想了，DP也勉强（显存不够），主要靠PP，再试试ZeRO1

参考链接：Model Parallelism: <https://huggingface.co/docs/transformers/v4.17.0/en/parallelism>