

LLMs 位置编码篇

来自：AiGC面试宝典

 Just do it!

2024年07月01日 22:22



三

LLMs 位置编码篇

- 动机
- 一、什么是位置编码？
- 二、为什么需要位置编码？
- 三、什么是绝对位置编码？
 - 3.1 训练式位置编码篇
 - 3.1.1 什么是 训练式位置编码？
 - 3.1.2 如何为每个位置的词向量注入位置信息呢？
 - 3.1.3 训练式位置编码篇 应用场景？
 - 3.1.4 训练式位置编码篇 存在哪些问题？
 - 3.2 Sinusoidal位置编码篇
 - 3.2.1 什么是 Sinusoidal位置编码？
 - 3.2.2 Sinusoidal位置编码 有哪些优点？
- 四、什么是相对位置编码？
- 五、旋转位置编码 RoPE篇
 - 5.1 旋转位置编码 RoPE 思路是什么？
 - 5.2 推导一下 旋转位置编码 RoPE ？
 - 5.3 旋转位置编码 RoPE 有什么优点？
 - 5.4 旋转位置编码 RoPE 被哪些 LLMs 应用？
- 六、长度外推问题篇
 - 6.1 什么是 长度外推问题？
 - 6.2 长度外推问题 的 解决方法 有哪些？
- 七、ALiBi (Attention with Linear Biases)篇
 - 7.1 ALiBi (Attention with Linear Biases) 思路是什么？
 - 7.2 ALiBi (Attention with Linear Biases) 的偏置矩阵是什么？有什么作用？
 - 7.3 ALiBi (Attention with Linear Biases) 有什么优点？
 - 7.4 ALiBi (Attention with Linear Biases) 被哪些 LLMs 应用？

动机

由于计算资源限制，目前的大模型大多在较小的上下文长度中进行训练，在推理中，若超出预训练的长度，模型的性能将会显著降低。于是涌现出了许多基于 RoPE 的长度外推的工作，旨在让大模型能够在预训练长度之外，取得更好的效果。

一、什么是位置编码？

句子中不同词语之前的位置信息十分重要，但是 self-attention 框架无法直接利用位置信息，因此研究者提出了许多方法将位置信息编码到学习过程中。

1. **绝对位置编码方法**：将位置信息直接加入到输入中；
2. **相对位置编码方法**：研究者通过微调 attention 的结构，使它具有识别 token 位置信息的能力。

二、为什么需要位置编码？

众所周知，transformer 模型之所以能够取得如此卓越的效果，其中的 Attention 机制功不可没，它的本质是计算输入序列中的每个 token 与整个序列的注意力权重。假设 q_m 和 k_n 分别表示词向量 q 位于位置 m 和词向量 k 位于位置 n ，在未添加位置信息的时候，

$$q_m = q, k_n = k,$$

则两者的注意力权重计算如下：

$$a_{m,n} = \frac{\exp\left(\frac{q_m^T k_n}{\sqrt{d}}\right)}{\sum_{j=1}^N \exp\left(\frac{q_m^T k_j}{\sqrt{d}}\right)}$$

我们会发现，在未加入位置信息的情况下，无论 q 和 k 所处的位置如何变化，它们之间的注意力权重 $a(m,n)$ 均不会发生变化，也就是位置无关，这显然与我们的直觉不符。对于两个词向量，如果它们之间的距离较近，我们希望它们之间的的注意力权重更大，当距离较远时，注意力权重更小。

为了解决这个问题，我们需要为模型引入位置编码，让每个词向量都能够感知到它在输入序列中所处的位置信息。我们定义如下函数，该函数表示对词向量 q 注入位置信息 m ，得到 q_m ：

$$q_m = f(q, m)$$

则 q_m 与 k_n 之间的注意力权重可表示为：

$$a_{m,n} = \frac{\exp\left(\frac{f(q,m)^T f(k,n)}{\sqrt{d}}\right)}{\sum_{j=1}^N \exp\left(\frac{f(q,m)^T f(k,j)}{\sqrt{d}}\right)}$$

三、什么是绝对位置编码？

绝对位置编码比较简单，研究者一般会将绝对位置信息加到输入中：在输入的第 k 个向量 x_k 中加入位置向量 p_k 得到 $p_k + x_k$ ，其中 p_k 仅与 k 相关。计算 p_k 的方法一般有两种：训练式位置编码与 Sinusoidal 位置编码。

3.1 训练式位置编码篇

3.1.1 什么是 训练式位置编码？

训练式位置编码，顾名思义就是每个位置的位置向量会随着模型一起训练。假设模型最大输入长度为 512，向量维度为 768，我们可初始化一个 512*768 的位置编码矩阵，该矩阵将参与模型的训练，从而学习得到每个位置所对应的向量表示。

3.1.2 如何为每个位置的词向量注入位置信息呢？

答案是相加，如以下公式所示，其中 p_m 表示第 m 个位置的位置向量：

$$q_m = f(q, m) = q + p_m$$

3.1.3 训练式位置编码篇 应用场景？

训练式位置编码广泛应用于早期的 transformer 类型的模型，如 BERT、GPT、ALBERT 等。

3.1.4 训练式位置编码篇 存在哪些问题？

模型不具有长度外推性，因为位置编码矩阵的大小是预设的，若对其进行扩展，将会破坏模型在预训练阶段学习到的位置信息。例如将 512*768 扩展为 1024*768，新拓展的 512 个位置向量缺乏训练，无法正确表示 512~1023 的位置信息。但早期大家对长文本输入的需求并不如现在迫切。

3.2 Sinusoidal 位置编码篇

3.2.1 什么是 Sinusoidal 位置编码？


Sinusoidal 位置编码是谷歌在 Transformer 模型中提出的一种绝对位置编码，它的形式如下，其中 d 表示词向量的维度， k 表示位置索引， $2i$ 和 $2i+1$ 表示位置向量的分量索引，例如 $p_{k,2i}$ 和 $p_{k,2i+1}$ 分别表示位置 k 的位置向量的第 $2i$ 和第 $2i+1$ 个分量：

$$\begin{cases} p_{k,2i} = \sin\left(k/10000^{2i/d}\right) \\ p_{k,2i+1} = \cos\left(k/10000^{2i/d}\right) \end{cases}$$

3. 2. 2 Sinusoidal 位置编码 有哪些优点？


1. 周期性

Sinusoidal 位置编码的每个分量都是正弦或余弦函数，所有每个分量的数值都具有周期性。如下图所示，每个分量都具有周期性，并且越靠后的分量，波长越长，频率越低。



2. 远程衰减性

Sinusoidal 位置编码还具有远程衰减的性质，具体表现为：对于两个相同的词向量，如果它们之间的距离越近，则他们的内积分数越高，反之则越低。如下图所示，我们随机初始化两个向量 q 和 k ，将 q 固定在位置 0 上， k 的位置从 0 开始逐步变大，依次计算 q 和 k 之间的内积。我们发现随着 q 和 k 的相对距离的增加，它们之间的内积分数震荡衰减。



四、什么是相对位置编码？

前面讲到相对位置编码是微调 Attention 矩阵的计算方式，先看看绝对位置编码怎样计算 Attention 矩阵：

$$\begin{aligned} q_m &= W_q(x_m + p_m) \\ k_n &= W_k(x_n + p_n) \\ q_m^T k_n &= x_m^T W_q^T W_k x_n + x_m^T W_q^T W_k p_n + p_m^T W_q^T W_k x_n + p_m^T W_q^T W_k p_n \end{aligned} \tag{1}$$

可以看到计算 attention 矩阵的过程如公式(1)所示，其中第一项和位置信息无关，第二至四项和位置信息相关。因此研究者通常是直接修改第二至四项的内容，直接在 attention 矩阵中添加相对位置信息。常见的有以下几种方法：

XLNET 式：如(2)所示，xlnet 将(1)中的二至四项都做了改变，具体的将 pn 替换为了 Sinusoidal 生成式编码 R_{n-m} ，将 pm 换成了两个可以训练的向量 u,v 。

$$q_m^T k_n = x_m^T W_q^T W_k x_n + x_m^T W_q^T W_k \tilde{R}_{n-m} + u^T W_q^T W_k x_n + v^T W_q^T W_k \tilde{R}_{n-m} \quad (2)$$

T5 式：如(3)所示，它的作者认为输入和位置间不应过多的交互，因此将第二、三项删除，将第四项都替换为一个可学习的偏执 $b_{m,n}$ ，这仅仅是在 Attention 矩阵的基础上加一个可训练的偏置项而已，十分简单。

$$q_m^T k_n = x_m^T W_q^T W_k x_n + b_{m,n} \quad (3)$$

DeBerta 式：和 T5 的构造相反，它舍弃了公式(1)中第四项，保留了第二、三项并将位置信息替换为了相对位置向量 R_{n-m} 。

$$q_m^T k_n = x_m^T W_q^T W_k x_n + x_m^T W_q^T W_k \tilde{R}_{n-m} + \tilde{R}_{n-m}^T W_q^T W_k x_n \quad (4)$$

五、旋转位置编码 RoPE 篇

5.1 旋转位置编码 RoPE 思路是什么？

作用在每个 transformer 层的 self-attention 块，在计算完 Q/K 之后，**旋转位置编码**作用在 Q/K 上，再计算 attention score。

5.2 推导一下 旋转位置编码 RoPE ?

Attention 的核心运算是内积，所以我们希望经过内积的结果能够带有相对信息。那么我们希望 q_m 和 k_n 的内积仅与输入 x_m, x_n 和他们的相对位置 $m-n$ 有关，那么我们可以假设存在函数 g ，使得：

$$q_m^T k_n = g(x_m, x_n, m - n)$$

为了方便理解我们可以先考虑二维形式，然后借助复数的运算法则来理解。首先分别用复数的指数形式表示各个向量变化，即有：

$$\begin{aligned} q_m &= (W_q x_m) e^{im\theta} \\ k_n &= (W_k x_n) e^{in\theta} \\ q_m^T k_n &= \text{Re}[(W_q x_m)(W_k x_n)^* e^{i(m-n)\theta}] \end{aligned}$$

PS1. 向量内积与复数乘积的关系为内积 $\langle i, j \rangle = \text{Re}(ij^*)$ ，其中 Re 表示复数的实部。

PS2. 这个形式证明过程可以参考论文的 3.4.1 节。但是要注意的是向量内积是标量，而

$g(x_m, x_n, m - n)$ 是向量，所以其公式(21) 应改为

$$q_m^T k_n = \langle f_q(x, m), f_k(x, n) \rangle = \text{Re}[(x_m, x_n, m - n)]$$

，这样公式(24)才好理解。

以 q_m 为例，假设 $e^{im\theta}$ 表示为模长为1的复数，根据复数乘法的几何意义， $(W_q x_m)e^{im\theta}$ 变换实际上对应着向量 $W_q x_m$ 的旋转，所以我们称之为“旋转式位置编码”，它还可以写成矩阵形式：

$$q_m = \begin{pmatrix} \cos m\theta & -\sin m\theta \\ \sin m\theta & \cos m\theta \end{pmatrix} W_q x_m$$

以 q_m 为例考虑多维情况，可以得到旋转式位置编码的一般形式为： $q_m = R_{\Theta,m}^d W_q x_m$ ，其中：

$$R_{\Theta,m}^d = \begin{pmatrix} \cos m\theta_1 & -\sin m\theta_1 & 0 & 0 & \cdots & 0 & 0 \\ \sin m\theta_1 & \cos m\theta_1 & 0 & 0 & \cdots & 0 & 0 \\ 0 & 0 & \cos m\theta_2 & -\sin m\theta_2 & \cdots & 0 & 0 \\ 0 & 0 & \sin m\theta_2 & \cos m\theta_2 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \cdots & \cos m\theta_{d/2} & -\sin m\theta_{d/2} \\ 0 & 0 & 0 & 0 & \cdots & \sin m\theta_{d/2} & \cos m\theta_{d/2} \end{pmatrix}$$

PS3. 矩阵 $R_{\Theta,m}^d$ 为正交矩阵，它不会改变向量的模长，因此通常来说它不会改变原模型的稳定性。

5.3 旋转位置编码 RoPE 有什么优点？

旋转位置编码通过绝对位置编码的方式实现了相对位置编码，有良好的外推性。

5.4 旋转位置编码 RoPE 被哪些 LLMs 应用？

LLaMA、GLM-130B、PaLM 等大语言模型就采用了旋转位置编码 RoPE。

六、长度外推问题篇

6.1 什么是 长度外推问题？

- 长度外推问题：训练、推理的长度不一致问题，主要体现在以下两方面：
 - 问题一：位置编码不一致（推理的时候有训练没见过的位置编码）；

- 。问题二：**attention span** 大小不一致（推理的时候 **attention span** 更大，导致扩增）；

6.2 长度外推问题的 解决方法 有哪些？


- 问题一解决方法：ALiBi、KERPLE、Sandwich、XPOS、PI、NTK-RoPE(目前看起来这个最强，不用 finetune)；
- 问题二解决方法：softmax 的时候加一个 $\log 512 \cdot n$ 系数；

七、ALiBi (Attention with Linear Biases)篇

7.1 ALiBi (Attention with Linear Biases) 思路是什么？

在计算完 attention score 后，直接为 attention score 矩阵加上一个预设好的偏置矩阵

7.2 ALiBi (Attention with Linear Biases) 的偏置矩阵是什么？有什么作用？



- ALiBi 的偏置矩阵：根据 q 和 k 的相对距离来惩罚 attention score
- 作用：相对距离越大，惩罚项越大相当于两个 token 的距离越远，相互贡献就越小。

7.3 ALiBi (Attention with Linear Biases) 有什么优点？

ALiBi 位置编码有良好的外推性

7.4 ALiBi (Attention with Linear Biases) 被哪些 LLMs 应用？

BLOOM 就采用了这种位置编码