

大模型-attention mask 篇

来自：AiGC面试宝典

宁静致远

2024年03月31日 20:29



- [大模型-attention mask 篇](#)
 - [1、prefix-tuning的prefix tokens是双向注意力吗？](#)
 - [2、chatglm1和chatglm2的attention mask是怎么样的？](#)
 - [3、llama的attention mask是怎么样的？](#)
 - [致谢](#)

1、prefix-tuning的prefix tokens是双向注意力吗？

chatglm1和chatglm2的prefix tokens训练是用的双向注意力机制。

2、chatglm1和chatglm2的attention mask是怎么样的？

- chatglm1
 1. 无论是训练还是推理，prompt部分用的双向注意力机制。
 2. 如果采用prefix-tuning的方式训练，prefix tokens和prompt都是用的双向注意力机制，并且prefix tokens能看见prompt。
 3. 在生成的时候prefix_tokens+prompt通过双向注意力机制存入kv cache，在一轮生成的过程中，不会再重新计算注意力。（但是在多轮对话中，会重新计算，因为又有了新的prompt）
- chatglm2
 4. 无论是训练还是推理，chatglm2中使用的是causal_mask

3、llama的attention mask是怎么样的？

无论是训练还是推理，llama中使用的是causal_mask