

- LLaMA 常见面试题篇
 - 一、相比较于llama而言，llama2有哪些改进，对于llama2是应该如何finetune?

一、相比较于 llama 而言，llama2 有哪些改进，对于 llama2 是应该如何 finetune?

llama 和 llama2 都是一种大型语言模型（Large Language Model，LLM），它们可以用于多种自然语言处理的任务，如文本生成、文本摘要、机器翻译、问答等。

llama 是一种基于 Transformer 的 seq2seq 模型，它使用了两种预训练任务，一种是无监督的 Span 级别的 mask，另一种是有监督的多任务学习。llama 将所有的下游任务都视为文本到文本的转换问题，即给定一个输入文本，生成一个输出文本。llama 使用了一个干净的大规模英文预训练数据集，包含了约 750GB 的文本数据。llama2 是 llama 的改进版本，它在以下几个方面有所提升：

- 数据量和质量：llama2 使用了比 llama1 多 40% 的数据进行预训练，其中包括更多的高质量和多样性的数据，例如来自 Surge 和 Scale 等数据标注公司的数据。
- 上下文长度：llama2 的上下文长度是 llama1 的两倍，达到了 4k 个标记，这有助于模型理解更长的文本和更复杂的逻辑。
- 模型架构：llama2 在训练 34B 和 70B 参数的模型时使用了分组查询注意力（Grouped-Query Attention，GQA）技术，可以提高模型的推理速度和质量。
- 微调方法：llama2 使用了监督微调（Supervised Fine-Tuning，SFT）和人类反馈强化学习（Reinforcement Learning from Human Feedback，RLHF）两种方法来微调对话模型（llama2-chat），使模型在有用性和安全性方面都有显著提升。

对 llama2 进行微调有以下步骤：

- 准备训练脚本：你可以使用 Meta 开源的 llama-recipes 项目，它提供了一些快速开始的示例和配置文件，以及一些自定义数据集和策略的方法。
- 准备数据集：你可以选择一个符合你目标任务和领域的数据集，例如 [GuanacoDataset](#)，它是一个多语言的对话数据集，支持 alpaca 格式。你也可以使用自己的数据集，只要按照 alpaca 格式进行组织即可。
- 准备模型：你可以从 Hugging Face Hub 下载 llama2 模型的权重，并转换为 Hugging Face 格式。
- 启动训练：你可以使用单 GPU 或多 GPU 来进行训练，并选择是否使用参数高效微调（Parameter-Efficient Fine-Tuning，PEFT）或量化等技术来加速训练过程。具体命令可以参考[这里](#)。