



LLMs 测试集 中 数据泄露 问题篇

来自：AiGC面试宝典

宁静致远

2024年01月27日 19:14

- LLMs 测试集 中 数据泄露 问题篇
 - 一、什么是 LLMs 测试集数据泄露 问题？
 - 二、如何解决 LLMs 测试集数据泄露 问题？
 - 三、是否可以 避开训练集来处理 LLMs 测试集数据泄露 问题？
 - 3.1 如何 判断 网络上是否有原题？
 - 3.2 如何 判断答案是否存在？
 - 3.3 性能差异对比
 - 四、常见测试集有多少比例的数据泄露？
 - 致谢

一、什么是 LLMs 测试集数据泄露 问题？

数据泄露（data contamination）是指模型测试集的数据被无意地(!)包含在了训练集中。
（如果是故意的，比如 train on 测试集，那就是另一个话题了）。

这种情况在大模型时代是很难避免的。其实在 Common Crawl 刚开始被用作训练集时就
有不少人意识到了这个问题。

比如这篇论文发现，在 T5 所用的 C4 数据集中，包含了 2-50% 不等的 GLUE
benchmark 的原题。导致 T5 在 GLUE 极亮眼的数据在当时遭到了不小质疑。

在此之后基本所有的 LLMs 在论文或者 report 中都会有单独的一章 Data contamination
analysis 来证明自己评测的可靠性。这里我附上几个具有代表性的例子：[GPT-3](#)，[GPT-4](#)，
[Llama-2](#)。

二、如何解决 LLMs 测试集数据泄露 问题？

处理数据泄露最成熟的方法是 识别测试集中的已泄露样本和未泄露样本，分别构建
dirty set 和 clean set，然后比较模型在这两个数据集上的性能差异。

注：GPT-3在De->En WMT16翻译任务上获得了43 bleu score的优秀总体成绩。但如果区分dirty和clean set的结果，
则GPT-3在未泄露样本（clean）上的分数只有40.8，而在泄露样本（dirty）上获得了47.4的超高分，这说明GPT-3通
过强大的记忆里在评测集上取得了额外的优势。其真实的翻译水平应接近40.3，而不是43分的总分。

然而，在我们实际研究或开发过程中，这种方法是很难复刻的。原因在于，这种方式需要获取 `base model` 完整的训练集，从而识别测试集里的干净和泄漏样本。

我们大部分常用的基座模型，包括一众中文大模型和 `Llama-2`，都没有开源其训练数据。

即使拿到训练数据，其庞大的数据量也会使整个处理过程非常耗时。例如，在 `Llama-2` 中为了识别测试集的数据泄露，在 `PySpark` 1500 核 cluster 运行了超过 7 个小时。

三、是否可以 避开训练集来处理 `LLMs` 测试集数据泄露 问题？

针对该问题，我们做出了一个假设：任何在网络上能够找到的测试集题目，都有很大的风险被包含在 `LLMs` 的训练数据中。

可以直接使用搜索引擎来区分测试集中的样例。把所有测试样例分为三类：

- 1. 干净样例：网络上找不到对应测试样例的题目或答案；
- 2. 题目泄漏样例：网络上能够找到原题，但答案并没有一起出现；
- 3. 题目-答案同时泄漏样例：测试样例的原题和答案同时出现在同一网页上。

3.1 如何 判断 网络上是否有原题？

判断网络上是否有原题的标准是：有 80% 以上的字符与测试样例完全重叠（用 `meteor` 来测量）。

3.2 如何 判断答案是否存在？

判断答案是否存在的标准是：使用完整的字符串匹配。

3.3 性能差异对比

比较模型在以上三个类别的性能差异。以 `C-Eval` 为例：

Model	Average	Clean	All Dirty	Input-and-Label Contaminated
qwen-7b-hf	58.73%	56.19% (↓ 2.54%)	61.69% (↑ 5.50%)	62.89% (↑ 6.70%)
baichuan2-7b-base-hf	55.73%	55.08% (↓ 0.65%)	56.49% (↑ 1.41%)	58.87% (↑ 3.79%)

这里 Average 是模型的总分，All Dirty 包含了所有在网上能找到原题的测试样例，而 Input-and-Label Contaminated 则是网上能同时找到原题和答案的样例。

如果只看总分（Average），那么 Qwen-7B 在 C-Eval 上超越了 Baichuan 整整 3%。

然而，模型能力的实际差距可能并没有那么大。结果显示 Qwen 在处理网上有原题的样本时性能格外出色，其准确率超越了 clean set 整整 5.5%。如此差距很可能说明 Qwen 在 C-Eval 上有潜在的过拟合现象。

相比之下，Baichuan 在 clean set 和泄露样例两者之间的差距则小的多，只有 1.41%。

如果只关注 Qwen 和 Baichuan 在 clean set 上的性能，那么两个模型实际上的差距只有 1.1%。

四、常见测试集有多少比例的数据泄露？

仔细观察下来，常见的 LLMs 测试集均有很严重的数据泄露现象。

例如 C-Eval 有超过 46.14% 的测试样例能够直接在 Common Crawl 里找到原题。MMLU 也有接近 37% 的测试样例完整地出现在 Common Crawl 里。

