



MOE (Mixture-of-Experts) 篇

来自: AiGC面试宝典

Just do it!

2024年06月23日 11:18

MOE (Mixture-of-Experts) 篇

- 一、为什么需要 MOE (Mixture-of-Experts) ?
- 二、MOE (Mixture-of-Experts) 的思路是什么样的?
- 三、介绍一下 MOE (Mixture-of-Experts) 分布式并行策略?
 - 3.1 MOE + 数据并行?
 - 3.2 MOE + 模型并行?
- 四、MoE大模型具备哪些优势?
- 五、MoE大模型具备哪些缺点?
- 六、MoE为什么可以实现更大模型参数、更低训练成本?
- 七、MoE如何解决训练稳定性问题?
- 八、MoE如何解决Fine-Tuning过程中的过拟合问题?
- 九、MOE算法在训练大语言模型时有哪些应用场景?

一、为什么需要 MOE (Mixture-of-Experts) ?


- 模型和训练样本的增加，导致了训练成本的平方级增长；
- 如何在牺牲极少的计算效率的情况下，把模型规模提升上百倍、千倍？

二、MOE (Mixture-of-Experts) 的思路是什么样的？

MOE (Mixture-of-Experts) 作为一种基于稀疏 MoE 层的深度学习模型架构，能够将大模型拆分成多个小模型(专家, expert)，然后在每轮迭代过程中，根据样本数量决定激活一定量的专家用于计算，实现节省计算资源的目的；同时，MOE (Mixture-of-Experts) 引入可训练并确保稀疏性的门(gate)机制，以保证计算能力的优化。

与密集模型不同,MoE 将模型的某一层扩展为多个具有相同结构的专家网络(expert), 并由门(gate)网络决定激活哪些 expert 用于计算，从而实现超大规模稀疏模型的训练。

以下图为例，模型包含 3 个模型层，如(a)到(b)所示，将中间层扩展为具有 n 个 expert 的 MoE 结构，并引入 Gating network 和 Top_k 机制，MoE 细节如下图(c)所示。




MOE (Mixture-of-Experts) 细节

计算过程如下述公式:

$$MoE(x) = \sum_{i=1}^n (G(x)_i E_i(x))$$
$$G(x) = TopK(softmax(W_g(x) + \epsilon))$$


注: 上述第 1 个公式表示了包含 n 个专家的 MoE 层的计算过程。具体来讲, 首先对样本 x 进行门控计算, W 表示权重矩阵; 然后, 由 **Softmax** 处理后获得样本 x 被分配到各个 expert 的权重; 然后, 只取前 k (通常取 1 或者 2) 个最大权重; 最终, 整个 MoE Layer 的计算结果就是选中的 k 个专家网络输出的加权和。

三、介绍一下 MOE (Mixture-of-Experts) 分布式并行策略?



3.1 MOE + 数据并行?


在数据并行模式下包含 MOE 架构, 门网络(gate)和专家网络都被复制地放置在各个运算单元上。下图展示了一个有三个专家的两路数据并行 MoE 模型进行前向计算的方式。



3.2 MOE + 模型并行？

该策略门网络依然是复制地被放置在每个计算单元上，但是专家网络被独立地分别放置在各个计算单元上。因此，需引入额外的通信操作，该策略可以允许更多的专家网络们同时被训练，而其数量限制与计算单元的数量(如：GPU 数量)是正相关的。

下图展示了一个有六个专家网络的模型被两路专家并行地训练。注意：专家 1-3 被放置在第一个计算单元上，而专家 4-6 被放置在第二个计算单元上。



该模式针对不同的模型和设备拓扑需要专门的并行策略，同时会引入额外的通信，因此，相较于数据并行+MOE 策略，侵入性更强。

除了上述两种 MOE 并行方案之外，还可以 MOE+数据并行+模型并行、MOE+ZeRO 增强的数据并行等。

四、MoE 大模型具备哪些优势？

1. 训练速度更快，效果更好。
2. 相同参数，推理成本低。
3. 扩展性好，允许模型在保持计算成本不变的情况下增加参数数量，这使得它能够扩展到非常大的模型规模，如万亿参数模型。
4. 多任务学习能力：MoE 在多任务学习中具备很好的新能（比如 Switch Transformer 在所有 101 种语言上都显示出了性能提升，证明了其在多任务学习中的有效性）。

五、MoE 大模型具备哪些缺点？

1. 训练稳定性：MoE 在训练过程中可能会遇到稳定性问题。
2. 通信成本：在分布式训练环境中，MoE 的专家路由机制可能会增加通信成本，尤其是在模型规模较大时。
3. 模型复杂性：MoE 的设计相对复杂，可能需要更多的工程努力来实现和优化。
4. 下游任务性能：MoE 由于其稀疏性，使得在 Fine-tuning 过程中容易出现过拟合。

六、MoE 为什么可以实现更大模型参数、更低训练成本？

MoE 使用了混合精度的方法，例如用 bfloat16 精度训练专家，同时对其余计算使用全精度进行。

较低的精度可以减少处理器间的通信成本、计算成本以及存储 **tensor** 的内存。

这主要是因为稀疏路由的原因，每个 token 只会选择 top-k 个专家进行计算。同时可以使用模型并行、专家并行和数据并行，优化 MoE 的训练效率。而负载均衡损失可提升每个 device 的利用率。

八、MoE 如何解决 Fine-Tuning 过程中的过拟合问题？

可以通过更大的 dropout（主要针对 expert）、更大的学习率、更小的 batch size。目前看到的主要是预训练的优化，针对 Fine-Tuning 的优化主要是一些常规的手段。

九、MOE 算法在训练大语言模型时有哪些应用场景？

MOE 算法在训练大语言模型时有以下几个应用场景：

- **解决多模态问题：**在多模态大模型的开发中，每个数据集可能包含来自文本、图像、语音等不同模态的数据，这些数据之间的特征和标注关系可能也不同。MoE 算法可以将不同模态的数据分发给专门的子模型(即“专家”)，让它们在各自擅长的领域内进行处理，并最后将结果汇总。
- **垂直领域应用：**随着应用场景的复杂化和细分化，大模型需要同时回答通识问题和解决专业领域问题。MOE 算法可以将不同领域的专家集合起来，让它们各自负责解答特定问题，最后将结果汇总。这种方式可以提高模型的性能，使其既能应对通用问题，又能在特定领域有更好的表现。
- **提高模型规模和效率：**MOE 算法通过引入稀疏性来提高模型的规模和效率。稀疏混合专家模型技术可以将大模型拆分为多个子模型，每个子模型只处理部分训练数据，从而减少了每个子模型的参数量和计算量，提高了训练效率和推理速度。
- **自然语言处理领域：**MOE 算法已经成功应用于自然语言处理领域。例如，谷歌在机器翻译方面引入 MOE 算法，通过在 LSTM 层之间增加 MOE 实现了性能的提升。此外，MOE 技术还被应用于 Transformer 架构中，提供了高效的分布式并行计算架构，进一步挖掘了 MOE 在自然语言处理领域中的潜力。