

LLMs 千面郎君

来自：AiGC面试宝典



2024年09月01日 23:39



三

一、大模型（LLMs）基础面

[大模型（LLMs）基础面](#)

- 1. 目前 主流的开源模型体系 有哪些？
- 2. prefix Decoder 和 causal Decoder 和 Encoder-Decoder 区别是什么？
- 3. 大模型LLM的 训练目标 是什么？
- 4. 涌现能力是啥原因？
- 5. 为何现在的大模型大部分是Decoder only结构？
- 6. 简单 介绍一下 大模型【LLMs】？
- 7. 大模型【LLMs】后面跟的 175B、60B、540B等 指什么？
- 8. 大模型【LLMs】具有什么优点？
- 9. 大模型【LLMs】具有什么缺点？

• [点击查看答案](#)

[Layer normalization 篇](#)

- Layer normalization-方法篇
 - Layer Norm 篇
 - Layer Norm 的计算公式写一下？
 - RMS Norm 篇 （均方根 Norm）
 - RMS Norm 的计算公式写一下？
 - RMS Norm 相比于 Layer Norm 有什么特点？
 - Deep Norm 篇
 - Deep Norm 思路？
 - 写一下 Deep Norm 代码实现？
 - Deep Norm 有什么优点？
- Layer normalization-位置篇
 - 1 LN 在 LLMs 中的不同位置 有什么区别么？如果有，能介绍一下区别么？
- Layer normalization 对比篇
 - LLMs 各模型分别用了 哪种 Layer normalization？
- [点击查看答案](#)

[LLMs 激活函数篇](#)

- 1 介绍一下 FFN 块 计算公式？
- 2 介绍一下 GeLU 计算公式？
- 3 介绍一下 Swish 计算公式？
- 4 介绍一下 使用 GLU 线性门控单元的 FFN 块 计算公式？
- 5 介绍一下 使用 GeLU 的 GLU 块 计算公式？
- 6 介绍一下 使用 Swish 的 GLU 块 计算公式？
- 7 各LLMs 都使用哪种激活函数？
- 8 Adam优化器和SGD的区别？
- [点击查看答案](#)

[Attention 升级面](#)

- 1 传统 Attention 存在哪些问题？

- 2 Attention 优化方向
- 3 Attention 变体有哪些?
- 4 Multi-Query Attention 篇
 - 4.1 Multi-head Attention 存在什么问题?
 - 4.2 介绍一下 Multi-Query Attention?
 - 4.3 对比一下 Multi-head Attention 和 Multi-Query Attention?
 - 4.4 Multi-Query Attention 这样做的好处是什么?
 - 4.5 有哪些模型 是 使用 Multi-Query Attention?
- 5 Grouped-query Attention
 - 5.1 什么是 Grouped-query Attention?
 - 5.2 有哪些大模型使用 Grouped-query Attention?
- 6 FlashAttention
- 7 并行 transformer block
- 8 attention计算复杂度以及如何改进?
- [点击查看答案](#)

[transformers 操作篇](#)

- a. 如何 利用 transformers 加载 Bert 模型?
- b. 如何 利用 transformers 输出 Bert 指定 hidden_state?
- c. BERT 获取最后一层或每一层网络的向量输出
- [点击查看答案](#)

[LLMs 损失函数篇](#)

- 一、介绍一下 KL 散度?
- 二、交叉熵损失函数写一下, 物理意义是什么?
- 三、KL 散度与交叉熵的区别?
- 四、多任务学习各loss差异过大怎样处理?
- 五、分类问题为什么用交叉熵损失函数不用均方误差 (MSE) ?
- 六、什么是信息增益?
- 七、多分类的分类损失函数(Softmax)?
- 八、softmax和交叉熵损失怎么计算, 二值交叉熵呢?
- 九、如果softmax的e次方超过float的值了怎么办?
- [点击查看答案](#)

[相似度函数篇](#)

- 一、除了cosin还有哪些算相似度的方法
- 二、了解对比学习嘛?
- 三、对比学习负样本是否重要? 负样本构造成本过高应该怎么解决?
- [点击查看答案](#)

[二、大模型 \(LLMs\) 进阶面](#)

- 一、什么是生成式大模型?
- 二、大模型是怎么让生成的文本丰富而不单调的呢?
- 三、LLMs 复读机问题
 - 3.1 什么是 LLMs 复读机问题?
 - 3.2 为什么会出现 LLMs 复读机问题?
 - 3.3 如何缓解 LLMs 复读机问题?
- 四、llama 系列问题
 - 4.1 llama 输入句子长度理论上可以无限长吗?
- 五、什么情况用Bert模型, 什么情况用LLaMA、ChatGLM类大模型, 咋选?
- 六、各个专业领域是否需要各自的大模型来服务?

- 七、如何让大模型处理更长的文本？
- [点击查看答案](#)

三、大模型 (LLMs) 微调面

[大模型 \(LLMs\) 微调面](#)

- 39 大模型 sft 过程中，为什么会出现第二个epoch的时候loss会突然下降问题？
- 1 如果想要在某个模型基础上做全参数微调，究竟需要多少显存？
- 2 为什么SFT之后感觉LLM傻了？
- 3 SFT 指令微调数据 如何构建？
 - 3.1 提升sft的prompt的代表性有什么好的方法？
 - 3.2 提升sft的prompt的数据量有什么好的方法？
- 4 领域模型Continue PreTrain 数据选取？
- 5 领域数据训练后，通用能力往往会有所下降，如何缓解模型遗忘通用能力？
- 6 领域模型Continue PreTrain，如何让模型在预训练过程中就学习到更多的知识？
- 7 进行SFT操作的时候，基座模型选用Chat还是Base？
- 8 领域模型微调 指令&数据输入格式 要求？
- 9 领域模型微调 领域评测集 构建？
- 10 领域模型词表扩增是不是有必要的？
- 11 如何训练自己的大模型？
- 12 训练中文大模型有啥经验？
- 13 指令微调的好处？
- 14 预训练和微调哪个阶段注入知识的？
- 15 想让模型学习某个领域或行业的知识，是应该预训练还是应该微调？
- 16 多轮对话任务如何微调模型？
- 17 微调后的模型出现能力劣化，灾难性遗忘是怎么回事？
- 18 微调模型需要多大显存？
- 19 大模型LLM进行SFT操作的时候在学习什么？
- 20 预训练和SFT操作有什么不同
- 21 样本量规模增大，训练出现OOM错
- 22 大模型LLM进行SFT 如何对样本进行优化？
- 23 模型参数迭代实验
- 24 微调大模型的一些建议
- 25 微调大模型时，如果 batch size 设置太小 会出现什么问题？
- 26 微调大模型时，如果 batch size 设置太大 会出现什么问题？
- 27 微调大模型时，batch size 如何设置问题？
- 28 微调大模型时，优化器如何？
- 29 哪些因素会影响内存使用？
- 30 进行领域大模型预训练应用哪些数据集比较好？
- 31 用于大模型微调的数据集如何构建？
- 32 大模型训练loss突刺原因和解决办法
 - 32.1 大模型训练loss突刺是什么？
 - 32.2 为什么大模型训练会出现loss突刺？
 - 32.3 大模型训练loss突刺 如何解决？
- 33 什么是Cosine优化器？在大模型中应该怎么设置cosine优化器的周期比较好？
- 34 在预训练阶段，若模型训练文本时不包含标记，而在后续预测阶段却添加了标记；或者相反，训练阶段加入了标记，但在预测时却没有使用，这两种情况下 benchmark 预测可能会遇到哪些问题呢？
- 35 SFT packing是什么？
- 36 SFT packing对SFT训练的影响是什么？
- 37 SFT阶段模型可以学习新知识？
- 38 建立sft数据主要需要关注什么方面？
- 40 解决显存不够的方法？
- 41 指令策略的选择及其影响
- 42 如何解决prompt泛化性？
- 43 大模型SFT最重要的是什么，分次SFT会发生什么？

- 44 大模型 supervised fine-tuning(SFT)的方法主要分为哪些?
- [点击查看答案](#)

[大模型 SFT Trick 篇](#)

- 一、常见 SFT 的开发流程是如何的?
- 二、训练数据要注重什么?
- 三、大 size 和小 size 模型的选择?
- 四、多任务训练时怎么确保每个任务都优秀?
- 五、SFT 真的不能学到知识?
- 六、怎么科学挑选数据集?
- 七、怎么解决幻觉问题
- 八、BERT 开发与 LLM 开发有什么不同之处?
- 九、该选什么微调方法, Full tuning\P-tuning\Lora?
- 十、SFT 还有什么方面值得研究?
- 十一、介绍一下训练过程中, 显存占用分析?
- 十二、介绍一下训练过程中, 显存占用分析?
- 十三、训练数据数据质量评估
- 十四、SFT 调参技巧
 - 14.1 有哪些参数可以调呢?
 - 14.2 Loss function 如何调参?
 - 14.3 Learning rate 和 Batch size 如何调参?
 - 14.4 Epoch number 和 early stopping 如何调参?
 - 14.5 Optimizer 如何调参?
 - 14.6 Activation function 如何调参?
 - 14.7 Weights initialization 如何调参?
 - 14.8 Regularization 如何调参?
- [点击查看答案](#)

[大模型 \(LLMs\) 训练经验帖](#)

- 分布式训练框架选择?
- LLMs 训练时 有哪些有用的建议?
- 模型大小如何选择?
- 加速卡如何选择?
- [点击查看答案](#)

四、大模型 (LLMs) langchain 面

[大模型 \(LLMs\) langchain 面](#)

- 一、什么是 LangChain?
- 二、LangChain 包含哪些 核心概念?
 - 2.1 LangChain 中 Components and Chains 是什么?
 - 2.2 LangChain 中 Prompt Templates and Values 是什么?
 - 2.3 LangChain 中 Example Selectors 是什么?
 - 2.4 LangChain 中 Output Parsers 是什么?
 - 2.5 LangChain 中 Indexes and Retrievers 是什么?
 - 2.6 LangChain 中 Chat Message History 是什么?
 - 2.7 LangChain 中 Agents and Toolkits 是什么?
- 三、什么是 LangChain Agent?
- 四、如何使用 LangChain ?
- 五、LangChain 支持哪些功能?
- 六、什么是 LangChain model?
- 七、LangChain 包含哪些特点?
- 八、LangChain 如何使用?

- 8.1 LangChain 如何调用 LLMs 生成回复?
- 8.2 LangChain 如何修改 提示模板?
- 8.3 LangChain 如何链接多个组件处理一个特定的下游任务?
- 8.4 LangChain 如何Embedding & vector store?
- 九、LangChain 存在哪些问题及方法方案?
 - 9.1 LangChain 低效的令牌使用问题
 - 9.2 LangChain 文档的问题
 - 9.3 LangChain 太多概念容易混淆, 过多的“辅助”函数问题
 - 9.4 LangChain 行为不一致并且隐藏细节问题
 - 9.5 LangChain 缺乏标准的可互操作数据类型问题
- 十、LangChain 替代方案?
- [点击查看答案](#)

[多轮对话中让AI保持长期记忆的8种优化方式篇](#)

- 一、前言
- 二、Agent 如何获取上下文对话信息?
 - 2.1 获取全量历史对话
 - 2.2 滑动窗口获取最近部分对话内容
 - 2.3 获取历史对话中实体信息
 - 2.4 利用知识图谱获取历史对话中的实体及其联系
 - 2.5 对历史对话进行阶段性总结摘要
 - 2.6 需要获取最新对话, 又要兼顾较早历史对话
 - 2.7 回溯最近和最关键的对话信息
 - 2.8 基于向量检索对话信息
- [点击查看答案](#)

[基于langchain RAG问答应用实战](#)

- [点击查看答案](#)

五、大模型 (LLMs) RAG 检索增强生成面

5.1 大模型 (LLMs) RAG 入门篇

[基于LLM+向量库的文档对话 经验面](#)

- 一、基于LLM+向量库的文档对话 基础面
 - 1.1 为什么 大模型 需要 外挂(向量)知识库?
 - 1.2. 基于LLM+向量库的文档对话 思路是怎样?
 - 1.3. 基于LLM+向量库的文档对话 核心技术是什么?
 - 1.4. 基于LLM+向量库的文档对话 prompt 模板 如何构建?
- 二、基于LLM+向量库的文档对话 存在哪些痛点?
- 三、基于LLM+向量库的文档对话 工程示例面
- [点击查看答案](#)

[RAG \(Retrieval-Augmented Generation\) 面](#)

- 一、LLMs 已经具备了较强能力了, 存在哪些不足点?
- 二、什么是 RAG?
 - 2.1 R: 检索器模块
 - 2.1.1 如何获得准确的语义表示?
 - 2.1.2 如何协调查询和文档的语义空间?
 - 2.1.3 如何对齐检索模型的输出和大语言模型的偏好?
 - 2.2 G: 生成器模块
 - 2.2.1 生成器介绍
 - 2.2.2 如何通过后检索处理提升检索结果?

- 2.2.3 如何优化生成器应对输入数据?
- 三、使用 RAG 的好处?
- 四、RAG V.S. SFT
- 五、介绍一下 RAG 典型实现方法?
 - 5.1 如何 构建 数据索引?
 - 5.2 如何 对数据进行 检索 (Retrieval) ?
 - 5.3 对于 检索到的文本, 如果生成正确回复?
- 六、介绍一下 RAG 典型案例?
- 七、RAG 存在什么问题?
- [点击查看答案](#)

5.2 大模型 (LLMs) RAG 版面分析篇

[大模型 \(LLMs\) RAG —— pdf解析关键问题](#)

- 一、为什么需要进行pdf解析?
- 二、为什么需要 对 pdf 进行解析?
- 三、pdf解析 有哪些方法, 对应的区别是什么?
- 四、pdf解析 存在哪些问题?
- 五、如何 长文档 (书籍) 中关键信息?
- 六、为什么要提取标题甚至是多级标题?
- 七、如何提取 文章标题?
- 八、如何区分单栏还是双栏pdf? 如何重新排序?
- 九、如何提取表格和图片中的数据?
- 十、基于AI的文档解析有什么优缺点?
- [点击查看答案](#)

[大模型 \(LLMs\) RAG 版面分析——表格识别方法篇](#)

- 一、为什么需要识别表格?
- 二、介绍一下 表格识别 任务?
- 三、有哪些 表格识别方法?
 - 3.1 传统方法
 - 3.2 pdfplumber表格抽取
 - 3.2.1 pdfplumber 如何进行 表格抽取?
 - 3.2.2 pdfplumber 常见的表格抽取模式?
 - 3.3 深度学习方法-语义分割
 - 3.3.1 table-ocr/table-detect: 票据图片复杂表格框识别(票据单元格切割)
 - 3.3.2 腾讯表格图像识别
 - 3.3.3 TableNet
 - 3.3.4 CascadeTabNet
 - 3.3.5 SPLERGE
 - 3.3.6 DeepDeSRT
- [点击查看答案](#)

[大模型 \(LLMs\) RAG 版面分析——文本分块面](#)

- 一、为什么需要对文本分块?
- 二、能不能介绍一下常见的文本分块方法?
 - 2.1 一般的文本分块方法
 - 2.2 正则拆分的文本分块方法
 - 2.3 Spacy Text Splitter 方法
 - 2.4 基于 langchain 的 CharacterTextSplitter 方法
 - 2.5 基于 langchain 的 递归字符切分 方法
 - 2.6 HTML 文本拆分 方法
 - 2.7 Mrrkdown 文本拆分 方法

- 2.8 Python代码拆分 方法
- 2.9 LaTeX 文本拆分 方法
- [点击查看答案](#)

5.3 大模型 (LLMs) RAG 检索策略篇

[大模型外挂知识库优化——如何利用大模型辅助召回？](#)

- 一、为什么需要使用大模型辅助召回？
 - 策略一：HYDE
 - 1. 介绍一下 HYDE 思路？
 - 2. 介绍一下 HYDE 问题？
 - 策略二：FLARE
 - 1. 为什么 需要 FLARE ？
 - 2. FLARE 有哪些召回策略？
- [点击查看答案](#)

[大模型外挂知识库优化——负样本挖掘篇](#)

- 一、为什么需要构建负难样本？
- 二、负难样本构建方法篇
 - 2.1 随机采样策略 (Random Sampling) 方法
 - 2.2 Top-K负例采样策略 (Top-K Hard Negative Sampling) 方法
 - 2.3 困惑负样本采样方法SimANS 方法
 - 2.4 利用 对比学习微调 方式构建负例方法
 - 2.5 基于批内负采样的对比学习方法
 - 2.6 相同文章采样方法
 - 2.7 LLM辅助生成软标签及蒸馏
- 辅助知识
 - 附一：梯度计算方法
- [点击查看答案](#)

5.4 大模型 (LLMs) RAG 评测篇

[RAG \(Retrieval-Augmented Generation\) 评测面](#)

- 一、为什么需要 对 RAG 进行评测？
- 二、RAG 有哪些评估方法？
- 三、RAG 有哪些关键指标和能力？
- 四、RAG 有哪些评估框架？
- [点击查看答案](#)

5.5 大模型 (LLMs) RAG 优化策略篇

[检索增强生成\(RAG\) 优化策略篇](#)

- 一、RAG基础功能篇
 - 1.1 RAG 工作流程
- 二、RAG 各模块有哪些优化策略？
- 三、RAG 架构优化有哪些优化策略？
 - 3.1 如何利用 知识图谱 (KG) 进行上下文增强？
 - 3.1.1 典型RAG架构中，向量数据库进行上下文增强 存在哪些问题？
 - 3.1.2 如何利用 知识图谱 (KG) 进行上下文增强？
 - 3.2 Self-RAG：如何让 大模型 对 召回结果 进行筛选？
 - 3.2.1 典型RAG架构中，向量数据库 存在哪些问题？
 - 3.2.2 Self-RAG：如何让 大模型 对 召回结果 进行筛选？
 - 3.2.3 Self-RAG 的创新点是什么？
 - 3.2.4 Self-RAG 的 训练过程？
 - 3.2.5 Self-RAG 的 推理过程？

- 3.2.6 Self-RAG 的代码实战?
- 3.3 多向量检索器多模态RAG篇
 - 3.3.1 如何让 RAG 支持 多模态数据格式?
 - 3.3.1.1 如何让 RAG 支持 半结构化RAG (文本+表格) ?
 - 3.3.1.2 如何让 RAG 支持 多模态RAG (文本+表格+图片) ?
 - 3.3.1.3 如何让 RAG 支持 私有化多模态RAG (文本+表格+图片) ?
 - 3.4 RAG Fusion 优化策略
 - 3.5 模块化 RAG 优化策略
 - 3.6 RAG 新模式 优化策略
 - 3.7 RAG 结合 SFT
 - 3.8 查询转换 (Query Transformations)
 - 3.9 bert在RAG中具体是起到了一个什么作用, 我刚搜了下nsp的内容, 但有点没法将这几者联系起来
- 四、RAG 索引优化有哪些优化策略?
 - 4.1 嵌入 优化策略
 - 4.2 RAG检索召回率低, 一般都有哪些解决方案呀。尝试过不同大小的chunk, 和混合检索。效果都不太好, 然后优化?
 - 4.3 RAG 如何 优化索引结构?
 - 4.4 如何通过 混合检索 提升 RAG 效果?
 - 4.5 如何通过 重新排名 提升 RAG 效果?
- 五、RAG 索引数据优化有哪些优化策略?
 - 5.1 RAG 如何 提升索引数据的质量?
 - 5.2 如何通过添加元数据 提升 RAG 效果?
 - 5.3 如何通过 输入查询与文档对齐 提升 RAG 效果?
 - 5.4 如何通过 提示压缩 提升 RAG 效果?
 - 5.5 如何通过 查询重写和扩展 提升 RAG 效果?
- RAG 未来发展方向
- Rag 的垂直优化
- RAG 的水平扩展
- RAG 生态系统
- [点击查看答案](#)

[RAG 关键痛点及对应解决方案](#)

- 前言
- 问题一: 内容缺失问题
 - 1.1 介绍一下 内容缺失问题?
 - 1.2 如何 解决 内容缺失问题?
- 问题二: 错过排名靠前的文档
 - 2.1 介绍一下 错过排名靠前的文档 问题?
 - 2.2 如何 解决 错过排名靠前的文档 问题?
- 问题三: 脱离上下文 — 整合策略的限制
 - 3.1 介绍一下 脱离上下文 — 整合策略的限制 问题?
 - 3.2 如何 解决 脱离上下文 — 整合策略的限制 问题?
- 问题四: 未能提取答案
 - 4.1 介绍一下 未能提取答案 问题?
 - 4.2 如何 解决 未能提取答案 问题?
- 问题五: 格式错误
 - 5.1 介绍一下 格式错误 问题?
 - 5.2 如何 解决 格式错误 问题?
- 问题六: 特异性错误
 - 6.1 介绍一下 特异性错误 问题?
 - 6.2 如何 解决 特异性错误 问题?
- 问题七: 回答不全面
 - 7.1 介绍一下 回答不全面 问题?
 - 7.2 如何 解决 回答不全面 问题?
- 问题八: 数据处理能力的挑战

- 8.1 介绍一下 数据处理能力的挑战 问题?
- 8.2 如何 解决 数据处理能力的挑战 问题?
- 问题九: 结构化数据查询的难题
 - 9.1 介绍一下 结构化数据查询的难题 问题?
 - 9.2 如何 解决 结构化数据查询的难题 问题?
- 问题十: 从复杂PDF文件中提取数据
 - 10.1 介绍一下 从复杂PDF文件中提取数据 问题?
 - 10.2 如何 解决 从复杂PDF文件中提取数据 问题?
- 问题十一: 备用模型
 - 11.1 介绍一下 备用模型 问题?
 - 11.2 如何 解决 备用模型 问题?
- 问题十二: 大语言模型 (LLM) 的安全挑战
 - 12.1 介绍一下 大语言模型 (LLM) 的安全挑战 问题?
 - 12.2 如何 解决 大语言模型 (LLM) 的安全挑战 问题?
- [点击查看答案](#)

[大模型 \(LLMs\) RAG 优化策略 —— RAG-Fusion篇](#)

- 一、RAG 有哪些优点?
- 二、RAG 存在哪些局限性?
- 三、为什么 需要 RAG-Fusion?
- 四、说一下 RAG-Fusion 核心技术?
- 五、说一下 RAG-Fusion 工作流程?
 - 5.1 多查询生成
 - 5.2 多查询生成 技术实现 (提示工程)?
 - 5.3 多查询生成 工作原理?
 - 5.4 逆向排名融合 (RRF)
 - 5.4.1 为什么选择RRF?
 - 5.4.2 RRF 技术实现?
 - 5.4.3 生成性输出 用户意图保留
 - 5.4.4 生成性输出 用户意图保留 技术实现
- 六、RAG-Fusion 的优势和不足
 - 6.1 RAG-Fusion 优势
 - 6.2 RAG-Fusion 挑战
- [点击查看答案](#)

5.6 大模型 (LLMs) Graph RAG篇

[Graph RAG \(Retrieval-Augmented Generation\) 面 —— 一种 基于知识图谱的大模型检索增强实现策略](#)

- 一、为什么需要 Graph RAG?
- 二、什么是 Graph RAG?
- 三、Graph RAG 思路介绍?
- 四、用代码 介绍 Graph RAG ?
- 五、用 示例 介绍 Graph RAG ?
- 六、Graph RAG 排序优化方式?
- [点击查看答案](#)

六、大模型 (LLMs) 参数高效微调(PEFT) 面

[大模型 \(LLMs\) 参数高效微调\(PEFT\) 面](#)

- a. 微调方法是啥? 如何微调?
- b. 为什么需要 PEFT?
- c. 介绍一下 PEFT?
- d. PEFT 有什么优点?
- e. 微调方法批处理大小模式GPU显存速度?

- f. Peft 和 全量微调区别?
- g. 多种不同的高效微调方法对比
- h. 当前高效微调技术存在的一些问题
- i. 高效微调技术最佳实践
- j. PEFT 存在问题?
- k. 能不能总结一下各种参数高效微调方法?

• [点击查看答案](#)

[适配器微调 \(Adapter-tuning\) 篇](#)

- 一、为什么 需要 适配器微调 (Adapter-tuning) ?
- 二、适配器微调 (Adapter-tuning) 思路?
- 三、适配器微调 (Adapter-tuning) 特点是什么?
- 四、AdapterFusion 思路 是什么?
- 五、AdapterDrop 思路 是什么?
- 六、AdapterDrop 特点 是什么?
- 七、MAM Adapter 思路 是什么?
- 八、MAM Adapter 特点 是什么?

• [点击查看答案](#)

[提示学习 \(Prompting\)](#)

- 一、为什么需要 提示学习 (Prompting) ?
- 二、什么是 提示学习 (Prompting) ?
- 三、提示学习 (Prompting) 有什么优点?
- 四、提示学习 (Prompting) 有哪些方法, 能不能稍微介绍一下它们间?
 - 4.1 前缀微调 (Prefix-tuning) 篇
 - 4.1.1 为什么需要 前缀微调 (Prefix-tuning) ?
 - 4.1.2 前缀微调 (Prefix-tuning) 思路是什么?
 - 4.1.3 前缀微调 (Prefix-tuning) 的优点是什么?
 - 4.1.4 前缀微调 (Prefix-tuning) 的缺点是什么?
 - 4.2 指示微调 (Prompt-tuning) 篇
 - 4.2.1 为什么需要 指示微调 (Prompt-tuning) ?
 - 4.2.2 指示微调 (Prompt-tuning) 思路是什么?
 - 4.2.3 指示微调 (Prompt-tuning) 优点是什么?
 - 4.2.4 指示微调 (Prompt-tuning) 缺点是什么?
 - 4.2.5 指示微调 (Prompt-tuning) 与 Prefix-tuning 区别 是什么?
 - 4.2.6 指示微调 (Prompt-tuning) 与 fine-tuning 区别 是什么?
 - 4.3 P-tuning 篇
 - 4.3.1 为什么需要 P-tuning?
 - 4.3.2 P-tuning 思路是什么?
 - 4.3.3 P-tuning 优点是什么?
 - 4.3.4 P-tuning 缺点是什么?
 - 4.4 P-tuning v2 篇
 - 4.4.1 为什么需要 P-tuning v2?
 - 4.4.2 P-tuning v2 思路是什么?
 - 4.4.3 P-tuning v2 优点是什么?
 - 4.4.4 P-tuning v2 缺点是什么?

• [点击查看答案](#)

[LoRA 系列篇](#)

一、LoRA篇

- 1.1 什么是 LoRA?
- 1.2 LoRA 的思路是什么?

- 1.3 LoRA 的特点是什么?
- 1.4 简单描述一下 LoRA?
- 1.5 解释一下 LORA 微调的原理和计算流程?
 - 二、LoRA变体篇
 - 2.1 QLoRA篇
 - 2.1.1 QLoRA 的思路是怎么样的?
 - 2.1.2 QLoRA 的特点是什么?
 - 2.1.3 QLORA相比LORA做了哪些改进?
 - 2.2 AdaLoRA篇
 - 2.1 AdaLoRA 的思路是怎么样的?
 - 2.3 LongLoRA篇
 - 2.3.1 为什么需要 LongLoRA?
 - 2.3.2 LongLoRA 思路是什么?
 - 2.3.3 介绍一下 shift short attention?
 - 三、Lora的矩阵怎么初始化? 为什么要初始化为全0?
 - 四、LoRA权重是否可以合入原模型?
 - 五、ChatGLM-6B LoRA后的权重多大?
 - 六、LoRA 微调优点是什么?
 - 七、LoRA微调方法为啥能加速训练?
 - 八、如何在已有LoRA模型上继续训练?
 - 九、LoRA 缺点是什么?
 - 十、LoRA这种微调方法和全参数比起来有什么劣势吗?
 - 十一、LORA应该作用于Transformer的哪个参数矩阵?
 - 十二、LoRA 微调参数量怎么确定?
 - 十三、Rank 如何选取?
 - 十四、alpha参数 如何选取?
 - 十五、LoRA 高效微调 如何避免过拟合?
 - 十六、微调大模型时, 优化器如何?
 - 十七、哪些因素会影响内存使用?
 - 十八、LoRA权重是否可以合并?
 - 十九、是否可以逐层调整LoRA的最优rank?
 - 二十、LORA 微调有哪些超参数需要注意?
 - 实践篇
 - i. LoRA 微调计算可训练参数的比例 如何确定?
 - ii. LoRA 微调结果如何保存?

• [点击查看答案](#)

如何使用 PEFT库 中 LoRA?

- 一、前言
- 二、如何 配置 LoraConfig?
- 三、模型 加入PEFT策略
 - 3.1 模型加载 策略有哪些?
 - 3.2 模型显存占用的部分有哪些?
 - 3.3 模型显存占用 优化策略?
 - 3.3.1 8bit量化 优化策略?
 - 3.3.2 梯度检查 优化策略?
 - 3.4 如何 向 模型 加入PEFT策略?
- 四、PEFT库 中 LoRA 模块 代码介绍
 - 4.1 PEFT库 中 LoRA 模块 整体实现思路
 - 4.2 PEFT库 中 LoRA 模块 `_find_and_replace()` 实现思路
 - 4.3 PEFT库 中 Lora层的 实现思路
 - 4.3.1 基类 LoraLayer 实现
 - 4.3.2 Linear 实现
- 五、使用 LoRA 对 大模型进行 高效参数微调, 如何进行存储?
- 六、使用 LoRA 对 大模型进行 推理, 如何进行加载?

- 七、huggingface大模型如何加载多个LoRA并随时切换?
- [点击查看答案](#)

[大模型 SFT 方式对比篇](#)

- 一、SFT 微调方案如何选择?
- 二、Full Fine Tuning vs Parameter-Efficient Fine-Tuning
- 三、Full Fine Tuning 篇
 - 3.1 介绍一下 Full Fine Tuning?
 - 3.2 介绍一下 Full Fine Tuning 优点?
 - 3.3 介绍一下 Full Fine Tuning 缺点?
- 四、Parameter-Efficient Fine-Tuning 篇
 - 4.1 介绍一下 Parameter-Efficient Fine-Tuning?
- 五、LoRA 篇
 - 5.1 介绍一下 LoRA?
 - 5.2 介绍一下 LoRA 流程?
 - 5.3 介绍一下 LoRA 优点?
 - 5.4 介绍一下 LoRA 缺点?
- 六、QLoRA 篇
 - 6.1 介绍一下 QLoRA?
 - 6.2 介绍一下 QLoRA 流程?
- 七、Adapter Tuning 篇
 - 6.1 介绍一下 Adapter Tuning?
 - 6.2 介绍一下 Adapter Tuning 流程?
- 八、Prefix Tuning 篇
 - 6.1 介绍一下 Prefix Tuning?
 - 6.2 介绍一下 Prefix Tuning 训练示例?
- 九、Prompt Tuning 篇
 - 9.1 介绍一下 Prompt Tuning?
 - 9.2 介绍一下 Prompt Tuning 优点?
 - 9.3 介绍一下 Prompt Tuning 缺点?
 - 9.4 介绍一下 Prompt Tuning 训练示例?
- 十、P-Tuning 篇
 - 10.1 介绍一下 P-Tuning?
 - 10.2 介绍一下 P-Tuning 优点?
 - 10.3 介绍一下 P-Tuning 缺点?
- 十一、P-Tuning V2 篇
 - 11.1 介绍一下 P-Tuning V2?
 - 11.2 介绍一下 P-Tuning V2 优点?
- [点击查看答案](#)

七、大模型 (LLMs) 推理面

[大模型 \(LLMs\) 推理面](#)

- a. 为什么大模型推理时显存涨的那么多还一直占着?
- b. 大模型在gpu和cpu上推理速度如何?
- c. 推理速度上, int8和fp16比起来怎么样?
- d. 大模型有推理能力吗?
- e. 大模型生成时的参数怎么设置?
- f. 有哪些省内存的大语言模型训练/微调/推理方法?
- g. 如何让大模型输出合规化
- h. 应用模式变更
- i. 模型输出的分布比较稀疏, 怎么处理?
- [点击查看答案](#)

八、大模型 (LLMs) 增量预训练篇

[大模型 \(LLMs\) 增量预训练篇](#)

- a. 为什么要增量预训练?
- b. 进行 增量预训练 需要做哪些准备工作?
- c. 增量预训练 所用 训练框架?
- d. 增量预训练 训练流程 是怎么样?
- e. 增量预训练 一般需要多大数据量?
- f. 增量预训练 过程中, loss 上升正常么?
- g. 增量预训练 过程中, lr 如何设置?
- h. 增量预训练 过程中, warmup_ratio 如何设置?
- i. warmup 的步数 对 大模型继续预训练 是否有影响?
- j. 学习率 大小 对 大模型继续预训练 后 上下游任务影响?
- k. 在初始预训练中使用 Rewarmup 对 大模型继续预训练 性能 影响?

• [点击查看答案](#)

[增量预训练 \(Pretrain\) 样本拼接篇](#)

- 一、推理过程 分哪些阶段?
 - 1.1 Prefill (输入理解与初始化) 阶段
 - 1.2 Decoding (递归推理与解码输出) 阶段
- 二、推理性能的评价指标?
 - 2.1 Throughput (吞吐量)
 - 2.2 First Token Latency (首字延迟)
 - 2.3 Latency (延迟)
 - 2.4 QPS (每秒请求数)
- 三、当前优化模型最主要技术手段有哪些?
 - 3.1 KVCache
 - 3.2 分布式推理
 - 3.3 流水线处理
 - 3.4 动态批处理
 - 3.5 低比特量化
 - 3.6 System Prompt
 - 3.7 预测生成长度
 - 3.8 Flash Attention
 - 3.9 Paged Attention
 - 3.10 精简Attention的MHA/GQA/MQA技术
 - 3.11 选择合适的硬件
- 四、推理加速框架有哪一个? 都有什么特点?
- 五、vLLM 篇
 - 5.1 vLLM 的功能有哪些?
 - 5.2 vLLM 的优点有哪些?
 - 5.3 vLLM 的缺点有哪些?
 - 5.4 vLLM 离线批量推理?
 - 5.5 vLLM API Server?
- 六、Text generation inference 篇
 - 6.1 介绍一下 Text generation inference?
 - 6.2 Text generation inference 的功能有哪些?
 - 6.3 Text generation inference 的优点有哪些?
 - 6.4 Text generation inference 的缺点有哪些?
 - 6.5 Text generation inference 的使用docker运行web server?

• [点击查看答案](#)

[增量预训练 \(Pretrain\) 样本拼接篇](#)

- 一、Pretrain阶段，为什么需要拼接拼接？
- 二、有哪些 拼接方式？
 - 2.1 拼接方式一：Random Concatenate
 - 2.2 拼接方式二：Random Concatenate + NoiseMask
 - 2.3 拼接方式三：Random Concatenate + Cluster
 - 2.4 拼接方式四：IN-CONTEXT PRETRAINING
- [点击查看答案](#)

[基于lora的llama2二次预训练](#)

- 一、为什么需要 对 llama2 做 基于lora的二次预训练？
- 二、基于lora的llama2二次预训练 的目标是什么？
- 三、基于lora的llama2二次预训练 的思想是什么？
- 四、基于lora的llama2二次预训练 语料构建思路？
- 五、如何 基于lora的llama2二次预训练？
 - 5.1 基于lora的llama2二次预训练 参数介绍
 - 5.2 基于lora的llama2二次预训练
- 六、如何 基于lora的llama2 微调？
 - 6.1 训练数据介绍
 - 6.2 基于lora的llama2 微调 参数介绍
 - 6.3 基于lora的llama2 微调
- 七、如何 使用 基于lora的llama2 做推理？
- [点击查看答案](#)

[九、大模型（LLMs）评测面](#)

1. 大模型怎么评测？
2. 大模型的honest原则是如何实现的？模型如何判断回答的知识是训练过的已知的知识，怎么训练这种能力？
3. 如何衡量大模型水平？
4. 大模型评估方法 有哪些？
5. 大模型评估工具 有哪些？
- [点击查看答案](#)

十、大模型（LLMs）强化学习面

[大模型（LLMs）强化学习面](#)

- 1 简单介绍强化学习？
- 2 简单介绍一下 RLHF？
- 3 奖励模型需要和基础模型一致吗？
- 4 RLHF 在实践过程中存在哪些不足？
- 5 如何解决 人工产生的偏好数据集成本较高，很难量产问题？
- 6 如何解决三个阶段的训练（SFT->RM->PPO）过程较长，更新迭代较慢问题？
- 7 如何解决 PPO 的训练过程同时存在4个模型（2训练，2推理），对计算资源的要求较高 问题？
- 8 强化学习跟大语言模型的本质联系是什么？
- 9 大语言模型与强化学习的本质联系？
- 10 GPT 到底是基于概率的还是基于价值？
- 11 强化学习究竟是如何与大语言模型做结合的？
- 12 强化学习与大模型的结合在公式中是如何体现？
- 13 强化学习与大模型的结合的好处？
- 14 reward 模型训练步骤中，为什么这一步骤在标注数据过程中不让人直接打分，而是去标排列序列呢？
- 15 reward 模型的 loss 是怎么计算的？
- 16 直接用训练 reward model 的数据精调模型，而不用强化学习，是否可行？为什么？
 - 16.1 reward模型、强化学习、SFT分别的作用？
 - 16.2 reward 模型、强化学习、SFT之间如何配合？
- 17 假如 reward model 不太准，怎么办？

- 18 chatGPT 强化学习训练阶段还有什么改进的空间和思路吗？
- 19 现阶段LLM的对齐阶段分为sft和rlhf阶段，我们可以跳过sft阶段直接进行rlhf么？
- [点击查看答案](#)

大模型 (LLMs) 强化学习——RLHF及其变种面

- 一、介绍一下 LLM的经典预训练Pipeline？
- 二、预训练 (Pre-training) 篇
 - 2.1 具体介绍一下 预训练 (Pre-training) ？
- 三、有监督微调 (Supervised Tinetuning) 篇
 - 3.1 具体介绍一下 有监督微调 (Supervised Tinetuning) ？
 - 3.2 有监督微调 (Supervised Tinetuning) 的训练数据格式是什么样？
 - 3.3 预训练 (Pre-training) vs 有监督微调 (Supervised Tinetuning) 区别？
- 四、对齐 (Alignment) 篇
 - 4.1 简单介绍一下 对齐 (Alignment) ？
- 五、Reinforcement Learning with Human Feedback (RLHF)篇
 - 5.1 简单介绍一下 RLHF 流程？
 - 5.2 如何在预训练好的模型上进行有监督微调？
 - 5.3 如何在有监督微调模型基础上创建一个RM模型？
 - 5.4 如何基于RM模型使用PPO算法微调SFT模型？
 - 5.5 instructGPT的原理，讲讲rlhf和reward？
- 六、LLaMA 2 的 RLHF 篇
 - 6.1 介绍一下 LLaMA 2 的 RLHF？
 - 6.2 LLaMA 2 中 Margin Loss 的实现逻辑？
 - 6.3 LLaMA 2 中 两个RM模型 的实现逻辑？
 - 6.4 LLaMA 2 中 拒绝采样 逻辑？
- 七、RLHF 替代方案篇
 - 7.1 为什么需要 RLHF 替代方案？
 - 7.2 RLHF 有哪些替代方案？
- 八、RLHF 实践篇
 - 8.1 RLHF 训练过程，怎么选取最优 checkpoint？
- [点击查看答案](#)

大模型 (LLMs) 强化学习—— PPO 面

- 一、大语言模型RLHF中的PPO主要分哪些步骤？
- 二、举例描述一下 大语言模型的RLHF？
- 三、大语言模型RLHF 采样篇
 - 3.1 什么是 PPO 中 采样过程？
 - 3.2 介绍一下 PPO 中 采样策略？
 - 3.3 PPO 中 采样策略中，如何评估“收益”？
- 四、在PPO过程中，reward model的效果上会有什么问题？
- 五、如何解决reward model的OOD的问题？
- 六、RLHF中PPO有什么问题，为什么大家都设计很多方法去替代它？
- [点击查看答案](#)

RLHF平替算法DPO篇

- RLHF平替算法DPO篇
 - 一、DPO vs RLHF？
 - 二、介绍一下 DPO的损失函数？
 - 三、DPO 微调流程 ？
 - 四、说一下 DPO 是如何简化 RLHF 的？
 - 五、DPO的第0步loss是固定的么？如果固定的话，值是多少？
 - 六、DPO是一个on-policy还是off-policy的算法，以及这样的算法有什么优劣？

- 七、DPO公式是由PPO的objective公式推导过来的，为什么DPO是off-policy算法，而PPO是on-policy算法，到底哪一步推导出了问题？
- 八、DPO为什么会在学习过程中training positive的概率和training negative的概率都同时下降？
- 九、在什么情况下DPO exactly 数学上等同于 PPO？
- 十、DPO的变体有哪些，主要解决DPO的什么问题？
- 十一、DPO训练后的模型为什么会输出越来越长？
- 代码解释

1. DPO损失函数 代码实现？
2. DPO 批次训练过程 代码实现？
3. LM的交叉熵计算 代码实现？

• [点击查看答案](#)

强化学习在自然语言处理下的应用篇

- 一、强化学习基础面
 - 1.1 介绍一下强化学习？
 - 1.2 介绍一下强化学习 的 状态 (States) 和 观测 (Observations) ？
 - 1.3 强化学习 有哪些 动作空间 (Action Spaces) ， 他们之间的区别是什么？
 - 1.4 强化学习 有哪些 Policy策略？
 - 1.5 介绍一下 强化学习 的 轨迹？
 - 1.6 介绍一下 强化学习 的 奖赏函数？
 - 1.7 介绍一下 强化学习问题？
- 二、RL发展路径 (至PPO)
 - 2.1 介绍一下 强化学习 中 优化方法 Value-based？
 - 2.2 介绍一下 强化学习 中 贝尔曼方程？
 - 2.3 介绍一下 强化学习 中 优势函数Advantage Functions？

• [点击查看答案](#)

十一、大模型 (LLMs) 训练集面

大模型 (LLMs) 训练集面

1. SFT (有监督微调) 的数据集格式？
2. RM (奖励模型) 的数据格式？
3. PPO (强化学习) 的数据格式？
4. 找数据集哪里找？
5. 微调需要多少条数据？
6. 有哪些大模型的训练集？
7. 进行领域大模型预训练应用哪些数据集比较好？
8. 如何选取和构建大模型微调数据？

• [点击查看答案](#)

大模型 (LLMs) LLM生成SFT数据方法面

- 四、大模型微调数据集格式篇
 - 一、SFT数据集如何生成？
 - 二、Self-Instruct 篇
 - 2.1 什么是 Self-Instruct ？
 - 2.2 Self-Instruct 处理思路？
 - 三、Backtranslation 篇
 - 3.1 什么是 Backtranslation？

• [点击查看答案](#)

十二、大模型 (LLMs) 显存问题面

大模型 (LLMs) 显存问题面

1. 大模型大概有多大，模型文件有多大？
2. 能否用4 * v100 32G训练vicuna 65b？
3. 如果就是想要试试65b模型，但是显存不多怎么办？
4. nB模型推理需要多少显存？
5. nB模型训练需要多少显存？
6. 如何估算模型所需的RAM？
7. 如何评估你的显卡利用率？
8. 测试你的显卡利用率 实现细节篇
 - a. 如何查看多机训练时的网速？
 - b. 如何查看服务器上的多卡之间的NVLINK topo？
 - c. 如何查看服务器上显卡的具体型号？
 - d. 如何查看训练时的flops？（也就是每秒的计算量）
 - e. 如何查看对deepspeed的环境配置是否正确？
 - f. tf32格式有多长？
 - g. 哪里看各类显卡算力比较？
 - h. (torch profiler) 如何查看自己的训练中通信开销？

• [点击查看答案](#)

[大模型 \(LLMs\) 显存优化策略篇](#)

- 一、介绍一下 gradient accumulation 显存优化方式？
- 二、介绍一下 gradient checkpointing 显存优化方式？
- [点击查看答案](#)

十三、大模型 (LLMs) 分布式训练面

[大模型 \(LLMs\) 分布式训练面](#)

- a. 理论篇
 - 1.1 训练 大语言模型 存在问题？
 - 1.2 什么是 点对点通信？
 - 1.3 什么是 集体通信？
 - 1.4 什么是 数据并行？
 - 1.5 数据并行 如何 提升效率？
 - 1.6 什么是 流水线并行？
 - 1.7 什么是 张量并行 (intra-layer)？
 - 1.8 数据并行 vs 张量并行 vs 流水线并行？
 - 1.9 什么是 3D并行？
 - 1.10 想要训练1个LLM，如果只想用1张显卡，那么对显卡的要求是什么？
 - 1.11 如果有N张显存足够大的显卡，怎么加速训练？
 - 1.12 如果显卡的显存不够装下一个完整的模型呢？
 - 1.13 PP推理时，是一个串行的过程，1个GPU计算，其他空闲，有没有其他方式？
 - 1.14 3种并行方式可以叠加吗？
 - 1.15 Colossal-AI 有1D/2D/2.5D/3D，是什么情况？
 - 1.16 除了3D并行有没有其他方式大规模训练？
 - 1.17 有了ZeRO系列，为什么还需要3D并行？
 - 1.18 平民适不适合玩3D并行？
 - 1.19 平民适不适合直接上多机多卡的ZeRO3（万兆网）？
 - 1.20 分布式并行及显存优化技术并行技术有哪些，都有什么特点？
 - 1.21 显存优化技术有哪些，都有什么特点？
 - 1.22 常见的分布式训练框架哪一些，都有什么特点？
- b. 实践篇
 - 2.1 假如有超多的8卡A100节点（DGX A100），如何应用3D并行策略？
 - 2.2 如果想构造这样一个大规模并行训练系统，训练框架怎么选？
 - 2.3 训练框架怎么选？
- c. 并行化策略选择篇

- 3.1 如何选择一款分布式训练框架？
- 3.2 如何选择一款分布式训练框架？
- 3.3 单GPU
- 3.4 单节点多卡
- 3.5 多节点多卡
- d. 问题篇
 - 4.1 推理速度验证
 - 4.2 并行化训练加速
 - 4.3 deepspeed 训练过程，报找不主机
 - 4.4 为什么 多机训练效率不如单机？
 - 4.5 多机训练不通，DeepSpeed配置问题
- [点击查看答案](#)

[图解分布式训练（一）—— 流水线并行（Pipeline Parallelism）面](#)

- 为什么需要流水线并行（Pipeline Parallelism）？
- 一、流水线并行（Pipeline Parallelism）优化目标是什么？
- 二、图解 流水线并行（Pipeline Parallelism）模型并行 必要性？
- 三、流水线并行（Pipeline Parallelism）图解？
- 四、流水线并行（Pipeline Parallelism）优缺点？
- [点击查看答案](#)

[图解分布式训练（二）—— nn.DataParallel面](#)

- 为什么需要nn.DataParallel？
- 一、pytorch中的GPU操作默认是什么样？
- 二、介绍一下 nn.DataParallel 函数？
- 三、nn.DataParallel 函数 处理逻辑 介绍一下？
- 四、nn.DataParallel 函数 常见问题及解答 有哪些？
 - 4.1 多GPU计算减少了程序运行的时间？
 - 4.2 如何保存和加载多GPU训练模型呢？
 - 4.3 为什么第一块卡的显存会占用的更多一些？
 - 4.4 直接使用nn.DataParallel的时候，训练采用多卡训练，会出现一个warning？
 - 4.5 device_ids 0 被占用问题
- 五、nn.DataParallel 函数 参数更新方式？
- 六、nn.DataParallel 函数 优点 介绍一下？
- 七、nn.DataParallel 函数 缺点 介绍一下？
- 八、nn.DataParallel 函数 实战？
- [点击查看答案](#)

[图解分布式训练（三）—— nn.parallel.DistributedDataParallel](#)

- 为什么需要 nn.parallel.DistributedDataParallel ？
- 一、什么是 DistributedDataParallel 核心 —— Ring-AllReduce？
- 二、nn.parallel.DistributedDataParallel 函数 介绍一下？
- 三、nn.parallel.DistributedDataParallel 函数 如何多卡加速训练？
- 四、nn.parallel.DistributedDataParallel 实现流程介绍一下？
- 五、nn.parallel.DistributedDataParallel 参数更新介绍一下？
- 六、nn.DataParallel(以下简称DP) vs DistributedDataParallel(以下简称DDP)介绍一下？
- 七、DistributedDataParallel(以下简称DDP) 优点有哪些？
- 八、DistributedDataParallel(以下简称DDP) 缺点有哪些？
- [点击查看答案](#)

[图解分布式训练（四）—— torch.multiprocessing 详细解析](#)

- 一、torch.multiprocessing 函数介绍一下?
- 二、torch.multiprocessing 函数如何使用?
- 三、介绍一下 共享CUDA张量?
- 四、介绍一下 共享策略?
- 五、torch.multiprocessing 函数使用
- [点击查看答案](#)

[图解分布式训练\(五\) —— AMP混合精度训练 详细解析](#)

- 为什么需要 AMP混合精度训练?
- 一、什么是自动混合精度训练(AMP)
- 二、为什么需要自动混合精度?
- 三、混合精度训练的的优点是什么?
- 四、混合精度训练的缺点是什么?
- 五、混合精度训练的关键技术是什么?
- 六、介绍一下 混合精度训练 动态损失缩放?
- 七、如何在PyTorch中使用自动混合精度?
- 八、如何使用 AMP混合精度训练 ?
- [点击查看答案](#)

[图解分布式训练\(六\) —— Pytorch的 DeepSpeed 详细解析](#)

- 一、为什么需要 Deepspeed?
- 二、DeepSpeed 基本概念 介绍一下?
 - 2.1 DeepSpeed 介绍
 - 2.2 DeepSpeed 基础的概念
 - 2.3 DeepSpeed 支持的功能
- 三、DeepSpeed 通信策略 介绍一下?
- 四、DeepSpeed 如何使用?
 - 4.1 DeepSpeed 安装
 - 4.2 DeepSpeed 使用
- 五、DeepSpeed 全部代码
- 六、优化器和调度器
 - 6.1 优化器
 - 6.2 调度器
- 七、训练精度
 - 7.1 自动混合精度
 - 7.2 NCCL
 - 7.3 apex
- 八、获取模型参数
 - 8.1 ZeRO-3 and Infinity Nuances
- 填坑笔记
 - i. ModuleNotFoundError: No module named 'torch._six'
 - ii. 为什么单卡的情况，也可以使用deepspeed?
 - iii. 不同 ZeRO 如何配置
 - iv. ZeRO-3 会比 ZeRO-2 慢很多 如何优化?
 - v. 如何选择不同的Zero stage和offload
 - vi. DeepSpeed 遇到问题，如何 确定 调参步骤?
 - vii. 如何估算需要的显存?
 - viii. 启动时，进程被杀死，并且没有打印出traceback
 - ix. loss是NaN
 - x. 确保一致性
 - xi. 如何配置 配置ssh?
 - xii. 如何配置 安装pdsh?
 - xiii. 如何配置 配置deepspeed文件?

- [点击查看答案](#)

[图解分布式训练（七）—— accelerate 分布式训练 详细解析](#)

- 一、为什么需要 accelerate 分布式训练？
- 二、什么是 accelerate 分布式训练？
- 三、accelerate 分布式训练 原理解释？
- 四、accelerate 分布式训练 如何实践？
- [点击查看答案](#)

[图解分布式训练（八）—— ZeRO 学习](#)

- 一、什么是 3D 并行？
- 二、3D 并行 策略有哪些？
- 三、为什么需要 ZeRO？
- 四、ZeRO 的核心思想是什么？
- 五、ZeRO 显存如何分配？
- 六、ZeRO 优化策略是怎么样？
- 七、ZeRO Offload后的计算流程是怎么样？
- [点击查看答案](#)

[大模型分布式训练故障恢复篇](#)

- 一、为什么 大模型分布式训练 需要 故障恢复？
- 二、如何获取最优的ckpt存储间隔？
- 三、ckpt存储能否实现异步或者部分掩盖？
- 四、断点续训/临终遗言是否真实可行？
- [点击查看答案](#)

[pytorch 分布式计算 坑/bug 梳理篇【*】](#)

- 一、使用 DistributedDataParallel（分布式并行）时，显存分布不均衡问题
- 二、如果是用pytorch实现同步梯度更新，自研 数据接口，出现 第一个epoch结尾处程序卡死问题
- 三、在微调大模型的时候，单机2卡的时候正常训练，但是采用4卡及以上，就会卡住，卡在读完数据和开始训练之间？
- [点击查看答案](#)

十四、大模型（LLMs）agent 面

[大模型（LLMs）agent 面](#)

- 一、什么是 大模型（LLMs）agent？
- 二、大模型（LLMs）agent 有哪些部分组成？
 - 2.1 介绍一下 规划（planning）？
 - 2.1.1 拆解子目标和任务分解
 - 2.1.1.1 如何进行 拆解子目标和任务分解？
 - 2.1.1.2 拆解子目标和任务分解 有哪些方法？
 - 2.1.2 模型自我反省
 - 2.1.2.1 如何进行 模型自我反省？
 - 2.1.2.2 模型自我反省 有哪些方法？
 - 2.2 介绍一下 记忆（Memory）？
 - 2.3 介绍一下 工具使用（tool use）？
- 三、大模型（LLMs）agent 主要 利用了 大模型 哪些能力？
- 四、结合 代码 讲解 大模型（LLMs）agent 思路？
 - 4.1 思路介绍
 - 4.2 实例一：利用大模型判断做选择

- 4.3 实例二：让大模型通过判断正确选择函数工具并输出
- 4.4 实例三：agent模板和解析
- 4.5 实例四：将 skylark 接入 langchain 中测试 agent
- 五、如何给LLM注入领域知识？
- 六、常见LLM Agent框架或者应用 有哪些？
- [点击查看答案](#)

[函数调用 Function Call 篇](#)

- 函数调用 Function Call 篇
 - 一、为什么需要 函数调用(function call)?
 - 二、什么是 函数调用(function call)?
 - 三、函数调用(function-call)目的是什么？
 - 四、怎么样使用函数调用？
 - 五、如何使用API完成函数调用？
 - 5.1 如何使用 函数调用(function-call) 构建 新闻机器人？
- [点击查看答案](#)

[十五、LLMs 位置编码篇](#)

- 一、什么是位置编码？
- 二、为什么需要位置编码？
- 三、什么是绝对位置编码？
 - 3.1 训练式位置编码篇
 - 3.1.1 什么是 训练式位置编码？
 - 3.1.2 如何为每个位置的词向量注入位置信息呢？
 - 3.1.3 训练式位置编码篇 应用场景？
 - 3.1.4 训练式位置编码篇 存在哪些问题？
 - 3.2 Sinusoidal位置编码篇
 - 3.2.1 什么是 Sinusoidal位置编码？
 - 3.2.2 Sinusoidal位置编码 有哪些优点？
- 四、什么是相对位置编码？
- 五、旋转位置编码 RoPE篇
 - 5.1 旋转位置编码 RoPE 思路是什么？
 - 5.2 推导一下 旋转位置编码 RoPE ？
 - 5.3 旋转位置编码 RoPE 有什么优点？
 - 5.4 旋转位置编码 RoPE 被哪些 LLMs 应用？
- 六、长度外推问题篇
 - 6.1 什么是 长度外推问题？
 - 6.2 长度外推问题 的 解决方法 有哪些？
- 七、ALiBi (Attention with Linear Biases)篇
 - 7.1 ALiBi (Attention with Linear Biases) 思路是什么？
 - 7.2 ALiBi (Attention with Linear Biases) 的偏置矩阵是什么？有什么作用？
 - 7.3 ALiBi (Attention with Linear Biases) 有什么优点？
 - 7.4 ALiBi (Attention with Linear Biases) 被哪些 LLMs 应用？
- [点击查看答案](#)

[十六、LLMs Tokenizer 篇](#)

[LLMs Tokenizer 篇](#)

- LLMs Tokenizer 篇
 - Byte-Pair Encoding(BPE)篇
 - 1 介绍一下 Byte-Pair Encoding(BPE) ？
 - 2 Byte-Pair Encoding(BPE) 如何构建词典？
 - 3 Byte-Pair Encoding(BPE) 具有什么优点？

- 4 Byte-Pair Encoding(BPE) 具有什么缺点?
- 5 手撕 Byte-Pair Encoding(BPE) ?
- Byte-level BPE 篇
 - 1 介绍一下 Byte-level BPE ?
 - 2 Byte-level BPE 如何构建词典?
 - 3 Byte-level BPE 具有什么优点?
 - 4 Byte-level BPE 具有什么缺点?
- WordPiece 篇
 - 1 介绍一下 WordPiece ?
 - 2 WordPiece 如何构建词典?
 - 3 WordPiece 具有什么优点?
 - 4 WordPiece 具有什么缺点?
 - 5 手撕 WordPiece ?
 - 6 WordPiece 与 BPE 异同点是什么?
- SentencePiece 篇
 - 1 介绍一下 SentencePiece ?
 - 2 SentencePiece 如何构建词典?
 - 3 SentencePiece 具有什么优点?
 - 4 SentencePiece 具有什么缺点?
 - 5 手撕 SentencePiece ?
- Transformer Tokenizer 篇
 - 1 介绍一下 Transformer Tokenizer ?
 - 2 Transformer Tokenizer 如何构建词典?
 - 3 Transformer Tokenizer 具有什么优点?
 - 4 Transformer Tokenizer 具有什么缺点?
 - 5 手撕 Transformer Tokenizer ?
- Unigram LM 篇
 - 1 介绍一下 Unigram LM ?
 - 2 Unigram LM 如何构建词典?
 - 3 Unigram LM 具有什么优点?
 - 4 Unigram LM 具有什么缺点?
 - 5 手撕 Unigram LM ?
- 对比篇
 - 1 对比一下 不同 分词器 优缺点?
 - 2 举例 介绍一下 不同 大模型LLMs 的分词效果?
 - 3 介绍一下 不同 大模型LLMs 的分词方式 的区别?
- [点击查看答案](#)

[怎么让英文大语言模型支持中文? \(一\) —— 构建中文tokenization](#)

- 一、为什么需要 构建中文tokenization?
- 二、如何对 原始数据预处理?
- 三、如何构建中文的词库?
- 四、如何使用transformers库加载sentencepiece模型?
- 五、如何合并英文词表和中文词表?
- 六、怎么使用修改后的词表?
- 总结一下 构建中文tokenization?
- [点击查看答案](#)

[怎么让英文大语言模型支持中文? \(二\) —— 继续预训练篇](#)

- 一、为什么需要进行继续预训练?
- 二、如何对 继续预训练 数据预处理?
- 三、如何 构建模型?
- 四、如何 使用模型?

- [点击查看答案](#)

[怎么让英文大语言模型支持中文？（三）——对预训练模型进行指令微调](#)

- 一、为什么需要对预训练模型进行指令微调？
- 二、对预训练模型进行指令微调 数据 如何处理？
- 三、对预训练模型进行指令微调 tokenization 如何构建？
- 四、对预训练模型进行指令微调 模型 如何构建？
- 五、是否可以结合 其他库 使用？
- [点击查看答案](#)

十七、大模型（LLMs）加速篇

[大模型\(LLM\)部署框架对比篇](#)

- 大模型(LLM)部署框架对比篇
- 一、为什么需要对大模型推理加速？
- 二、大模型(LLM)部署框架对比总览
- 三、大模型(LLM)部署优化策略
 - 3.1 大模型(LLM)部署优化策略——量化
 - 3.1.1 介绍一下 大模型(LLM)量化方法？
 - 3.1.2 一般会对大模型(LLM)中哪些模块进行量化？
 - 3.1.3 大模型(LLM)量化方法
 - 3.2 大模型(LLM)部署优化策略——KV Cache
 - 3.2.1 介绍一下 大模型(LLM) KV Cache 方法？
 - 3.2.2 为什么需要 大模型(LLM) KV Cache 方法？
 - 3.3 大模型(LLM)部署优化策略——Flash Attention
 - 3.3.1 介绍一下 大模型(LLM) Flash Attention 方法？
 - 3.4 大模型(LLM)部署优化策略——Paged Attention
 - 3.4.1 介绍一下 大模型(LLM) Paged Attention 方法？
 - 3.5 大模型(LLM)部署优化策略——Continuous batching
 - 3.5.1 介绍一下 大模型(LLM) Continuous batching 方法？
 - 3.6 大模型(LLM)部署优化策略——Speculative Decoding
 - 3.6.1 介绍一下 大模型(LLM) Speculative Decoding 方法？
 - 3.7 大模型(LLM)部署优化策略——Medusa
 - 3.7.1 介绍一下 大模型(LLM) Medusa 方法？
- [点击查看答案](#)

[大模型（LLMs）推理加速篇](#)

- 一、推理过程 分哪些阶段？
 - 1.1 Prefill（输入理解与初始化）阶段
 - 1.2 Decoding（递归推理与解码输出）阶段
- 二、推理性能的评价指标？
 - 2.1 Throughput（吞吐量）
 - 2.2 First Token Latency（首字延迟）
 - 2.3 Latency（延迟）
 - 2.4 QPS（每秒请求数）
- 三、当前优化模型最主要技术手段有哪些？
 - 3.1 KVCache
 - 3.2 分布式推理
 - 3.3 流水线处理
 - 3.4 动态批处理
 - 3.5 低比特量化
 - 3.6 System Prompt
 - 3.7 预测生成长度

- 3.8 Flash Attention
- 3.9 Paged Attention
- 3.10 精简Attention的MHA\GQA\MQA技术
- 3.11 选择合适的硬件
- 四、推理加速框架有哪一个？都有什么特点？
- 五、vLLM 篇
 - 5.1 vLLM 的功能有哪些？
 - 5.2 vLLM 的优点有哪些？
 - 5.3 vLLM 的缺点有哪些？
 - 5.4 vLLM 离线批量推理？
 - 5.5 vLLM API Server？
- 六、Text generation inference 篇
 - 6.1 介绍一下 Text generation inference？
 - 6.2 Text generation inference 的功能有哪些？
 - 6.3 Text generation inference 的优点有哪些？
 - 6.4 Text generation inference 的缺点有哪些？
 - 6.5 Text generation inference 的使用docker运行web server？
- [点击查看答案](#)

[大模型 \(LLMs\) 加速篇](#)

- a. 当前优化模型最主要技术手段有哪些？
- b. 推理加速框架有哪一个？都有什么特点？
- 3 vLLM 篇
 - 3.1 vLLM 的功能有哪些？
 - 3.2 vLLM 的优点有哪些？
 - 3.3 vLLM 的缺点有哪些？
 - 3.4 vLLM 离线批量推理？
 - 3.5 vLLM API Server？
- 4 Text generation inference 篇
 - 4.1 介绍一下 Text generation inference？
 - 4.2 Text generation inference 的功能有哪些？
 - 4.3 Text generation inference 的优点有哪些？
 - 4.4 Text generation inference 的缺点有哪些？
 - 4.5 Text generation inference 的使用docker运行web server？
- [点击查看答案](#)

[LLMs 推理性能面](#)

- 一、介绍一下 LLMs 的文本生成过程？
- 二、如何准确衡量模型的推理速度呢？
- 三、如果对整体推理时延有具体目标，有哪些有效的启发式方法来评估模型？
- 四、LLMs 推理存在哪些挑战？
- [点击查看答案](#)

[LLM \(大语言模型\) 部署加速方法——PagedAttention篇](#)

- 一、vLLM 用于大模型并行推理加速 存在什么问题？
- 二、vLLM 如何 优化 大模型并行推理加速？
- 三、什么是 PagedAttention？
- 四、PagedAttention 如何存储 连续的key和value？
- 五、PagedAttention 技术细节？
- 六、PagedAttention 如何 实现安全共享？
- 七、PagedAttention 源码介绍？
- [点击查看答案](#)

[大模型推理加速工具——vLLM](#)

- 一、引言
 - 1.1 前言
 - 1.2 为什么 需要 vLLM ?
 - 1.3 vLLM 具有哪些特点 ?
 - 1.4 vLLM 支持哪些 Huggingface 模型 ?
- 二、vLLM 性能如何?
- 三、vLLM 依赖包
- 四、vLLM 如何安装?
- 五、vLLM 如何使用?
- 六、vLLM 分布式推理与服务
- [点击查看答案](#)

[LLM \(大语言模型\) 部署加速方法——Faster Transformer篇](#)

- 一、为什么需要 FasterTransformer?
- 二、FasterTransformer 介绍一下?
- 三、FasterTransformer 核心是什么?
- 四、FasterTransformer 优化?
- [点击查看答案](#)

[纯Python超轻量高性能LLM推理框架——LightLLM](#)

- 一、引言
 - 1.1 前言
 - 1.2 为什么 需要 LightLLM ?
 - 1.3 目前 LLM推理框架 有 哪些?
- 二、LightLLM 介绍一下?
 - 2.1 什么是 LightLLM ?
 - 2.2 Token Attention 介绍?
 - 2.3 Efficient Router 介绍?
- 三、LightLLM 性能表现 介绍?
- 四、LightLLM 依赖包 有哪些?
- 五、LightLLM 如何安装?
 - 5.1 下载 LightLLM
 - 5.2 安装 LightLLM 依赖
 - 5.3 安装 LightLLM
- 六、LightLLM 如何使用?
 - 6.1 启动 LightLLM 服务
- 填坑笔记
 - LightLLM 支持模型 LLMs 模型?
- [点击查看答案](#)

[LLM推理技术之StreamingLLM: 如何拥有无限长生成能力](#)

- 一、前言
 - 1.1 大型语言模型 (LLM) 存在什么问题?
 - 1.2 StreamingLLM 背景介绍
 - 1.3 StreamingLLM 核心问题?
 - 1.4 StreamingLLM 存在哪些挑战?
 - 1.5 目前主流地增加输入文本长度的方法有哪些?
- 二、StreamingLLM 的思路是什么?
- [点击查看答案](#)

[SwiftInfer —— 大模型无限流式输入推理飙升46%，打破多轮对话长度限制](#)

- StreamingLLM 篇
 - 一、为什么需要 StreamingLLM?
 - 二、StreamingLLM 思路是什么?
 - 三、StreamingLLM 优点是什么?
- SwiftInfer 篇：基于TensorRT的StreamingLLM实现
 - 一、为什么需要 SwiftInfer?
 - 二、SwiftInfer 思路是什么?
 - 三、SwiftInfer 优点是什么?
- [点击查看答案](#)

十八、大模型幻觉（LLM Hallucination）面

[大模型幻觉（LLM Hallucination）面](#)

- 一、什么是大模型幻觉?
- 二、为什么LLM会产生幻觉?
- 三、为什么需要解决LLM的幻觉问题?
- 四、幻觉一定是有害的吗?
- 五、幻觉有哪些不同类型?
- 六、如何度量幻觉?
- 七、如何缓解LLM幻觉?
 - 7.1 通过使用外部知识验证主动检测和减轻幻觉
 - 7.2 事实核心采样
 - 7.3 SelfCheckGPT
- 八、LLMs什么时候最容易产生幻觉?
- [点击查看答案](#)

[大模型的幻觉问题篇](#)

- 一、什么是 大模型幻觉问题?
- 二、为什么 会出现 大模型幻觉问题?
- 三、如何 评估 大模型幻觉问题?
- 四、如何 缓解 大模型幻觉问题?
- [点击查看答案](#)

[如何缓解大模型幻觉?](#)

- 一、为什么 会出现 大模型幻觉?
- 二、如何 缓解 大模型幻觉?
- [点击查看答案](#)

十九、LLMs 对比篇

[LLMs 对比篇](#)

- LLMs 对比篇
 - 一、谈谈你对当前出现的各种大模型的见解?
 - 二、目前大模型常见的 base 模型训练和 chat 模型训练 方式 的区别么?
 - 三、llama、baichuan、ChatGLM、Bloom 和 qwen 等开源大模型技术对比篇
 - 3.1 llama 系列篇
 - 3.1.1 llama 篇
 - 3.1.1.1 llama 训练数据 介绍
 - 3.1.1.2 llama 模型参数量 介绍
 - 3.1.1.3 llama 模型结构 介绍

- 3.1.1.4 llama 训练目标 介绍
- 3.1.1.5 llama tokenizer 介绍
- 3.1.1.6 llama 衍生模型 介绍
- 3.1.1.7 llama 词表扩展: Chinese LLaMA
- 3.2.1 llama2 篇
 - 3.2.1 llama2 系列 数据预处理方式?
 - 3.2.2 llama2 系列 Tokenizer 处理方式?
 - 3.2.3 llama2 系列 Architectural?
 - 3.2.4 llama2 系列 content长度?
- 3.2 Mistral 7B 系列篇
 - 3.2.1 Mistral 7B Architectural?
- 3.3 Qwen 系列篇
 - 3.3.1 Qwen 系列 数据预处理方式?
 - 3.3.2 Qwen 系列 Tokenizer 处理方式?
 - 3.3.3 Qwen 系列 ARCHITECTURE?
- 3.4 Baichuan 系列篇
 - 3.4.1 Baichuan2 篇
 - 3.4.1.1 Baichuan2 系列 数据预处理方式?
 - 3.4.1.2 Baichuan2 系列 Tokenizer 处理方式?
 - 3.4.1.2 Baichuan2 系列 Architecture ?
- 3.5 GLM 系列篇
 - 3.5.1 ChatGLM-6B 篇
 - 3.5.1.1 ChatGLM-6B 结构特点?
 - 3.5.1.2 ChatGLM-6B 训练目标?
 - 3.5.1.3 ChatGLM-6B tokenizer?
- 3.6 BLOOM 系列篇
 - 3.6.1 BLOOM 篇
 - 3.6.1.1 BLOOM 训练数据构建?
 - 3.6.1.2 BLOOM 模型参数量?
 - 3.6.1.3 BLOOM 模型结构?
 - 3.6.1.4 BLOOM 训练目标?
 - 3.6.1.5 BLOOM tokenizer?
- 四、分析与总结?
 - 4.1 大模型训练共同点?
 - 4.2 大模型训练不同点?
- 五、对比
 - 5.1 LLaMA、ChatGLM 和 BLOOM 对比
 - 5.2 LLaMA、ChatGLM 和 BLOOM 的 tokenizer 比较
 - 5.3 LLaMA、ChatGLM 和 BLOOM 的结果 比较

• [点击查看答案](#)

[LLMs 对比篇](#)

大模型-attention mask 篇

- 1、prefix-tuning的prefix tokens是双向注意力吗?
 - 2、chatglm1和chatglm2的attention mask是怎么样的?
 - 3、llama的attention mask是怎么样的?
- [点击查看答案](#)

[百川智能baichuan7B、13B、53B、baichuan2 总结篇](#)

- 一、baichuan-7B篇
 - i. 你了解baichuan-7B解构么? 介绍一下?
 - ii. baichuan-7B 如何 收集原始数据并 构建 训练数据?
 - iii. baichuan-7B 如何 提高 训练稳定性和吞吐?

- 二、baichuan-13B篇
 - i. 相比于 baichuan-7B, baichuan-13B 的特点体现在哪里?
 - ii. 如何对 baichuan-13B 进行推理和部署?
 - iii. 如何对 baichuan-13B 进行微调?
- 三、baichuan-53B篇
 - 3.1 baichuan-53B 相比于 baichuan-7B 和 baichuan-13B 有哪些优势?
 - 3.2 baichuan-53B 如何对 预训练数据 做处理?
 - 3.3 baichuan-53B 如何进行 搜索增强?
- 四、baichuan2篇
 - 4.1 baichuan2 与 其他大模型 对比
- 五、baichuan 数据构建篇
 - 5.1 baichuan 进行微调时, 领域数据: 通用数据配比?
- [点击查看答案](#)

LLaMa 篇

- 一、相比较于llama而言, llama2有哪些改进, 对于llama2是应该如何finetune?
- [点击查看答案](#)

GPT 经验篇

- 一、gpt源码past_key_value是干啥的?
- 二、gpt onebyone 每一层怎么输入输出?
- 三、bert和gpt有什么区别
- 四、文本生成的几大预训练任务?
- 五、讲讲T5和Bart的区别, 讲讲bart的DAE任务?
- 六、讲讲Bart和Bert的区别?
- 七、gpt3和gpt2的区别?
- [点击查看答案](#)

二十、思维链 Chain-of-Thought (COT) 篇

[思维链 Chain-of-Thought \(COT\) 篇](#)

- 一、什么是思维链提示?
- 二、思维链提示本质是什么?
- 三、思维链提示 与 标准的提示学习方法有什么不同?
- 四、思维链提示 为什么可以提高语言模型的复杂推理能力?它的优势在哪里?
- 五、思维链提示 适用场景 有 哪些?
- 六、思维链提示 目前还存在哪些不足点?
- 七、思维链提示 对推动语言模型复杂推理能力研究有哪些启发和影响?
- 八、思维链提示 对实现真正的通用人工智能仍面临哪些挑战?
- 九、如何通过增加模型规模来获得语言模型强大的思路链推理能力的?这与模型获得的哪些能力有关?
- 十、你认为可以在哪些其他方面应用“思路链提示”这一思路来提升语言模型的能力?
- 十一、如果需要你对 思维链提示 进行改进, 你觉得你会改进哪些地方?
- 十二、思维链提示 未来研究方向?
- 十三、常见面试题
 - 13.1 对COT(Chain-of-Thought Prompt)和Instruction Tuning的理解?
- [点击查看答案](#)

[思维链 Chain-of-Thought \(COT\) 变体篇](#)

- 思维链 Chain-of-Thought (COT) · 思维链的启蒙
 - i. 什么是 思维链 Chain-of-Thought (COT) ?
 - ii. 思维链 Chain-of-Thought (COT) 是思路是什么?
 - iii. 思维链 Chain-of-Thought (COT) 存在问题?

- 思维树 Tree of Thoughts (TOT) : 一种用树结构解决复杂问题的方法
 - i. 为什么需要 思维树 Tree of Thoughts (TOT) ?
 - ii. 什么是 思维树 Tree of Thoughts (TOT) ?
 - iii. 思维树 Tree of Thoughts (TOT) 涉及问题有哪些?
- 思维图 Graph of Thoughts (GOT) : 一种把思维链过程建模层图结构的方法
 - i. 为什么 需要 思维图 Graph of Thoughts (GOT) ?
 - ii. 什么是 思维图 Graph of Thoughts (GOT) ?
 - iii. 思维图 Graph of Thoughts (GOT) 核心思想是什么?
- 思维算法 Algorithm of Thoughts (AOT) : 一种用DFS/BFS示例解决问题的方法
 - i. 为什么 需要 思维算法 Algorithm of Thoughts (AOT) ?
 - ii. 思维算法 Algorithm of Thoughts (AOT) 思路是什么?
 - iii. 思维算法 Algorithm of Thoughts (AOT) vs 其他 COT 的区别?
- 思维链 Chain-of-Thought (COT) 有哪些 应用场景?
- 思维链 Chain-of-Thought (COT) 有哪些 局限性?
- [点击查看答案](#)

[小样本提示学习篇](#)

- 一、什么是Zero-shot提示方法?
- 二、什么是Few-shot提示方法?
- 三、阐述One-shot和Few-shot提示策略及其应用场景?
- 四、什么是逐步Zero-shot
- 五、定义Zero-shot-CoT提示策略并描述其应用方法?
- 六、解释Few-shot-CoT提示策略及其实际使用方式?
- 七、Few-shot-LtM策略包含哪些主要阶段及其职责?
- [点击查看答案](#)

[二十一、LLMs 测试集中数据泄露 问题篇](#)

- 一、什么是 LLMs 测试集数据泄露 问题?
- 二、如何解决 LLMs 测试集数据泄露 问题?
- 三、是否可以 避开训练集来处理 LLMs 测试集数据泄露 问题?
 - 3.1 如何 判断 网络上是否有原题?
 - 3.2 如何 判断答案是否存在?
 - 3.3 性能差异对比
- 四、常见测试集有多少比例的数据泄露?
- [点击查看答案](#)

[二十二、MOE \(Mixture-of-Experts\) 篇](#)

[22.1 MOE \(Mixture-of-Experts\) 篇](#)

- 一、为什么需要 MOE (Mixture-of-Experts) ?
- 二、MOE (Mixture-of-Experts) 的思路是什么样的?
- 三、介绍一下 MOE (Mixture-of-Experts) 分布式并行策略?
 - 3.1 MOE + 数据并行?
 - 3.2 MOE + 模型并行?
- 四、MoE大模型具备哪些优势?
- 五、MoE大模型具备哪些缺点?
- 六、MoE为什么可以实现更大模型参数、更低训练成本?
- 七、MoE如何解决训练稳定性问题?
- 八、MoE如何解决Fine-Tuning过程中的过拟合问题?
- 九、MOE算法在训练大语言模型时有哪些应用场景?
- [点击查看答案](#)

[22.2 MOE大模型对比篇](#)

- DeepSpeed-MoE
- PAI-Megatron-Patch MoE
- [点击查看答案](#)

二十三、大模型蒸馏篇

[大模型蒸馏篇](#)

- 一、知识蒸馏和无监督样本训练？
- 二、对知识蒸馏知道多少，有哪些改进用到了？
- 三、谈一下对模型量化的了解？
- 四、模型压缩和加速的方法有哪些？
- 五、你了解的知识蒸馏模型有哪些？
- [点击查看答案](#)

[LLMs 浮点数篇](#)

- 一、fp32和fp16的区别，混合精度的原理
- 二、半精度是什么？
- 三、半精度的理论原理是什么？
- [点击查看答案](#)

[自定义 CUDA 函数的轻量级包装器 —— bitsandbytes篇](#)

- 一、什么是 bitsandbytes？
- 二、如何才能使用 bitsandbytes？
- 三、如何使用 bitsandbytes？
- [点击查看答案](#)

二十四、大模型（LLMs）软硬件配置面

1. 建议的软件环境是什么？
- [点击查看答案](#)

二十五、Token及模型参数准备篇

1. 预训练数据 Token 重复 是否影响 模型性能？
 2. SFT需要训练Token数？
- [点击查看答案](#)

二十六、多模态常见面试篇

[多模态常见面试篇](#)

- 一、最近关注的论文，多模态视觉大模型(CLIP,DALLE)？
- 二、blip2的架构，优势和之前多模态模型的区别？
- 三、多模态融合后，怎样知道最终结果受哪种模态影响更大？
- 四、多模态中常见的SOTA模型有哪些？
- 五、介绍一下stable diffusion的原理？
- [点击查看答案](#)

二十七、NLP常见面试篇

[NLP Trick 篇](#)

- 一、怎么处理类别不平衡？
- 二、有了解其他模型去尝试解决长度限制的方案吗？
- [点击查看答案](#)

文本分类常见面试题篇

- 一、文本分类任务有哪些应用场景？
- 二、文本分类的具体流程？
- 三、fastText的分类过程？ fastText的优点？
- 四、TextCNN进行文本分类的过程？
- 五、TextCNN可以调整哪些参数？
- 六、文本分类任务使用的评估指标有哪些？
- [点击查看答案](#)

文本摘要常见面试题篇

- 一、抽取式摘要和生成式摘要存在哪些问题？
- 二、Pointer-generator network解决了什么问题？
- 三、文本摘要有哪些应用场景？
- 四、几种ROUGE指标之间的区别是什么？
- 五、BLEU和ROUGE有什么不同？
- [点击查看答案](#)

命名实体识别常见面试题篇

- 一、CRF 常见面试题
 - 1.1 什么是CRF？ CRF的主要思想是什么？
 - 1.2 CRF的三个基本问题是什么？
 - 1.3 线性链条件随机场的参数化形式？
 - 1.4 CRF的优缺点是什么？
 - 1.5 HMM与CRF的区别？
 - 1.6 生成模型与判别模型的区别？
- 二、HMM 常见面试题
 - 2.1 什么是马尔科夫过程？
 - 2.2 马尔科夫过程的核心思想是什么？
 - 2.3 隐马尔可夫算法中的两个假设是什么？
 - 2.4 隐马尔可夫模型三个基本问题是什么？
 - 2.5 隐马尔可夫模型三个基本问题的联系？
 - 2.6 隐马尔可夫算法存在哪些问题？
- [点击查看答案](#)

向量检索常见面试题篇

- 一、向量检索库总结
 - 1.1 Annoy
 - 1.1.1 Annoy 介绍
 - 1.1.2 Annoy 使用
 - 1.2 Faiss
 - 1.2.1 Faiss 介绍
 - 1.2.2 Faiss 主要特性
 - 1.2.3 Faiss 使用
 - 1.3 Milvus
 - 1.4 ElasticSearch
 - 1.4.1 ElasticSearch 介绍
 - 1.4.2 什么是倒排索引呢？

- 1.4.3 ES机制

• [点击查看答案](#)

二十八、其他常见面试篇

[LLMs 其他 Trick](#)

1. huggingface 下载不了模型问题？

• [点击查看答案](#)

二十九、大模型推理加速——KV Cache篇

[大模型推理加速——KV Cache篇](#)

- 大模型推理加速——KV Cache篇
 - 一、介绍一下 KV Cache是啥？
 - 二、为什么要进行 KV Cache？
 - 2.1 不使用 KV Cache 场景
 - 2.2 使用 KV Cache 场景
 - 三、说一下 KV Cache 在 大模型中的应用？
 - 3.1 KV Cache 在 Llama 推理流程中应用？
 - 四、KV Cache 优点？
 - 五、KV Cache 缺点？
 - 六、KV Cache 优化策略？
 - 6.1 PageAttention显存优化
 - 6.2 MHA、GQA、MQA优化技术
 - 6.3 FlashAttention优化技术

• [点击查看答案](#)

三十、大模型——角色扮演大模型篇

[大模型——角色扮演大模型篇](#)

- 大模型——角色扮演大模型篇
 - 一、什么是角色扮演大模型？
 - 二、为什么需要角色扮演大模型？
 - 三、角色扮演大模型 相比于 通用大模型 具有哪些区别？
 - 四、能否通俗易懂的介绍【角色扮演大模型】？
 - 五、有哪些策略可以提升【角色扮演大模型】能力？

• [点击查看答案](#)